

Fiche récapitulative – STA211

Réseaux de neurones – Cours 2

Réseaux de neurones convolutionnels (ConvNets) et LeNet

Nicolas Thome (CNAM)

14 juin 2026

Résumé

Cette fiche présente les réseaux de neurones convolutionnels (ConvNets / CNN), qui tirent parti de la structure spatiale des données (images, audio) via la convolution, le partage de poids et le pooling. Le modèle historique LeNet-5 (LeCun et al., 1989) est détaillé comme étude de cas avec son architecture complète et ses performances sur MNIST.

Table des matières

1	Limites des réseaux fully connected (MLP)	2
2	La convolution	2
2.1	Connectivité locale et partage de poids	2
2.2	Convolution 2D	2
2.3	Convolution vs corrélation croisée	2
2.4	Convolution sur tenseurs (couche convolutionnelle)	2
3	Le pooling	3
3.1	Objectif	3
3.2	Max pooling	3
3.3	Types de pooling	3
4	Architecture d'un ConvNet	3
5	Étude de cas : LeNet-5 (LeCun et al., 1989)	3
5.1	Architecture	3
5.2	Détails	4
5.3	Résultats sur MNIST	4
	Questions clés (QCM)	4

Limites des réseaux fully connected (MLP)

Les réseaux entièrement connectés (MLP) présentent trois limitations majeures pour les données de signaux :

1. **Explosion du nombre de paramètres** : même une seule couche cachée génère un nombre de poids colossal (ex : image 32×32 en entrée, couche cachée de 1000 neurones $\Rightarrow$ 1 million de paramètres).
2. **Ignorance de la topologie spatiale** : la représentation vectorielle perd toute notion de voisinage. Le MLP est indifférent aux permutations des pixels d'entrée.
3. **Absence d'invariance** : un faible décalage en entrée peut produire une représentation complètement différente.

La convolution

Connectivité locale et partage de poids

Pour pallier ces limites, on introduit deux idées clés :

1. **Connectivité locale (sparse connectivity)** : chaque neurone caché n'est connecté qu'à une petite région locale de l'entrée (champ récepteur), inspiré du cortex visuel.
2. **Partage de poids (shared weights)** : le même filtre (noyau) est appliqué à toutes les positions spatiales, réduisant considérablement le nombre de paramètres.

Convolution 2D

Soit une image f et un filtre h de taille impaire d . La convolution 2D est définie par :

$$f'(i, j) = (f \star h)(i, j) = \sum_{n=-\frac{d-1}{2}}^{\frac{d-1}{2}} \sum_{m=-\frac{d-1}{2}}^{\frac{d-1}{2}} f(i-n, j-m) h(n, m) \quad (1)$$

La sortie pour 1 filtre est une carte 2D ; pour K filtres on obtient K cartes 2D.

Convolution vs corrélation croisée

La corrélation croisée (*cross-correlation*) est similaire mais sans symétrisation du masque :

$$f'(i, j) = (f \otimes h)(i, j) = \sum_n \sum_m f(i+n, j+m) h(n, m) \quad (2)$$

En pratique, les frameworks Deep Learning implémentent la corrélation croisée (plus simple) et les filtres sont appris.

Convolution sur tenseurs (couche convolutionnelle)

Pour une image couleur (3 canaux) ou une carte de features profonde, la convolution s'applique sur toute la profondeur :

$$f'(i, j) = \sum_{k=1}^K \sum_n \sum_m f(i-n, j-m, k) h(n, m, k) + b \quad (3)$$

Chaque filtre produit une carte 2D ; F filtres produisent F cartes empilées en un **tenseur** de profondeur F .

À retenir. La couche convolutionnelle est une opération affine (convolution linéaire + biais), suivie d'une non-linéarité (ReLU, sigmoïde, etc.).

Le pooling

Objectif

- Le **pooling** (sous-échantillonnage) permet de :
- Réduire la résolution spatiale.
 - Apporter une invariance aux translations locales.
 - Diminuer le nombre de paramètres.

Max pooling

- La valeur maximale dans une fenêtre $p \times p$ est retenue avec un pas (stride) s :
- Exemple : fenêtre 2×2 , stride 2 $\Rightarrow$ division par 2 de chaque dimension spatiale.
 - Offre une invariance partielle aux translations : un décalage inférieur à la taille de la fenêtre de pooling ne modifie pas nécessairement le maximum.

Types de pooling

Type	Opération
Max pooling	Maximum dans la fenêtre
Average pooling	Moyenne dans la fenêtre
Sum pooling	Somme (pondérée par un paramètre appris)

Architecture d'un ConvNet

Un réseau convolutionnel (ConvNet / CNN) est constitué de l'empilement de blocs élémentaires :

$$\boxed{\text{Convolution} + \text{Non-linéarité} + \text{Pooling}} \quad (4)$$

Après plusieurs blocs, les cartes de features sont aplaties et connectées à des couches entièrement connectées (fully connected) pour la classification finale.

À retenir. Les ConvNets exploitent la structure locale des données : pixel voisins, échantillons temporels proches, etc. Chaque bloc extrait des motifs de plus en plus abstraits.

Étude de cas : LeNet-5 (LeCun et al., 1989)

Architecture

LeNet-5 est le premier réseau convolutionnel moderne, développé pour la reconnaissance de chiffres manuscrits (MNIST).

Couche	Type	Taille	Maps $\times$ Dim.	# Param.
Entrée	Image	32×32	$1 \times 32 \times 32$	0
C1	Convolution (5×5 , 6 filtres)		$6 \times 28 \times 28$	156
S2	Pooling (2×2 , stride 2)		$6 \times 14 \times 14$	12
C3	Convolution (5×5 , 16 filtres)		$16 \times 10 \times 10$	1516
S4	Pooling (2×2 , stride 2)		$16 \times 5 \times 5$	32
C5	Convolution (5×5 , 120 filtres)		$120 \times 1 \times 1$	48 210
F6	Fully connected		84	10 164
F7	Fully connected (sortie)		10	850
Total				~60 000

Détails

C1 : 6 filtres 5×5 , pas de padding $\Rightarrow 28 \times 28$. Paramètres : $(5 \times 5 + 1) \times 6 = 156$.

S2 : sous-échantillonnage 2×2 stride 2, somme pondérée + biais $\Rightarrow 14 \times 14$.

C3 : 16 filtres 5×5 , connexion sélective aux cartes de S2 (non fully connected) $\Rightarrow 10 \times 10$.

S4 : identique à S2 $\Rightarrow 5 \times 5$.

C5 : 120 filtres $5 \times 5 \times 16$ (profondeur totale) $\Rightarrow$ cartes 1×1 (vecteur de 120).

F6 : 84 neurones fully connected.

F7 : 10 neurones de sortie (softmax).

Résultats sur MNIST

- Ensemble original : 60 000 images, erreur test 0,95%.
- Avec 540 000 distortions artificielles : erreur test 0,8%.
- Déploiement réussi pour la lecture de codes postaux aux États-Unis.

Questions clés (QCM)

1. Quelle est la principale limitation des MLP pour les images ?
 - (a) Ils sont trop lents à l'inférence
 - (b) Explosion du nombre de paramètres et ignorance de la topologie spatiale
 - (c) Ils ne peuvent pas apprendre
 - (d) Ils nécessitent trop de données

Réponse : b (explosion des paramètres et perte de la topologie).

2. Que permet le partage de poids (shared weights) ?
 - (a) Augmenter le nombre de paramètres
 - (b) Réduire considérablement le nombre de paramètres à apprendre
 - (c) Accélérer le calcul
 - (d) Éviter le sur-apprentissage

Réponse : b (réduction du nombre de paramètres).

3. Quelle est la différence entre convolution et corrélation croisée ?
 - (a) Aucune
 - (b) La corrélation croisée ne symétrise pas le masque
 - (c) La convolution est plus rapide
 - (d) La corrélation croisée utilise des filtres plus grands

Réponse : b (pas de symétrisation du masque).

4. Quel est le rôle d'une couche de pooling ?
 - (a) Augmenter la résolution
 - (b) Apporter une invariance aux translations locales et réduire la dimension spatiale
 - (c) Remplacer la convolution
 - (d) Initialiser les poids

Réponse : b (invariance aux translations et sous-échantillonnage).

5. Dans LeNet-5, combien de filtres la couche C1 possède-t-elle ?
 - (a) 1
 - (b) 6
 - (c) 16
 - (d) 120

Réponse : b (6 filtres 5×5).

6. Quelle est la taille des cartes de sortie de C1 dans LeNet-5 ?
 - (a) 32×32
 - (b) 28×28
 - (c) 14×14
 - (d) 10×10

Réponse : b (28×28 , convolution 5×5 sans padding).

7. Combien de paramètres LeNet-5 a-t-il au total ?
 - (a) $\sim 6\,000$
 - (b) $\sim 60\,000$
 - (c) $\sim 600\,000$
 - (d) $\sim 6\,000\,000$

Réponse : b ($\sim 60\,000$ paramètres).

8. Quel jeu de données a servi pour évaluer LeNet-5 ?

- (a) ImageNet
- (b) MNIST
- (c) CIFAR-10
- (d) COCO

Réponse : b (MNIST, chiffres manuscrits).

9. Quelle performance LeNet-5 atteint-elle sur MNIST avec distortions artificielles ?

- (a) 5% d'erreur
- (b) 0,8% d'erreur
- (c) 10% d'erreur
- (d) 0,1% d'erreur

Réponse : b (0,8% d'erreur test).

10. Qui a proposé LeNet-5 ?

- (a) Hinton et al.
- (b) LeCun et al.
- (c) Krizhevsky et al.
- (d) Goodfellow et al.

Réponse : b (LeCun et al., 1989).

Références

- [1] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, L. D. Jackel. *Back-propagation applied to handwritten zip code recognition*. Neural Computation, 1(4):541–551, 1989.
- [2] I. Goodfellow, Y. Bengio, A. Courville. *Deep Learning*. MIT Press, 2016.