

Fiche récapitulative – STA211

Réseaux de neurones – Cours 3

Histoire du Deep Learning, architectures modernes CNN et perspectives

Nicolas Thome (CNAM)

14 juin 2026

Résumé

Ce cours retrace l’histoire du Deep Learning des années 80 à nos jours, puis présente les modules modernes des CNN (ReLU, dropout, data augmentation, padding), le transfert d’apprentissage (deep features, fine-tuning), l’adaptation de tâche (localisation, segmentation) et les défis ouverts (apprentissage non supervisé, GANs, VQA).

Table des matières

1	Histoire du Deep Learning	2
1.1	Années 80 : LeNet-5 (déjà vu au cours 2)	2
1.2	Années 90 : hiver du Deep Learning	2
1.3	Années 2000 : Sac de mots (BoW)	2
1.4	2006 : renouveau du Deep Learning	2
1.5	2010 : percée en reconnaissance vocale	2
1.6	2012 : la révolution AlexNet	2
2	Modules modernes des CNN	2
2.1	Non-linéarités	2
2.2	Data augmentation	3
2.3	Dropout (Hinton et al., 2012)	3
2.4	Padding	3
2.5	Overlapping pooling	3
3	Outils et bibliothèques	3
3.1	Exemple Keras : régression logistique sur MNIST	3
3.2	Exemple Keras : CNN	4
4	Transfert d’apprentissage	4
4.1	Problématique	4
4.2	Deep Features (transfert pur)	4
4.3	Fine-tuning	4
4.4	Résultats expérimentaux	4
4.5	Adaptation de tâche	5
5	Enjeux actuels et perspectives	5
5.1	Apprentissage non supervisé	5
5.2	Nouvelles tâches en IA	5
5.3	Limites actuelles	5
5.4	Conclusion	5
	Questions clés (QCM)	5

Histoire du Deep Learning

Années 80 : LeNet-5 (déjà vu au cours 2)

LeNet-5 (LeCun et al., 1989) pose les bases des CNN : convolution + pooling + FC. ~60 000 paramètres, erreur test 0,95 % sur MNIST (0,8 % avec distortions). Déploiement pour la lecture de codes postaux.

Années 90 : hiver du Deep Learning

- Réseaux profonds perçus comme de la « black magic » : boîte noire, manque d'interprétabilité, optimisation non convexe difficile.
- Âge d'or des méthodes à noyaux : SVM, kernel trick, théorie de la généralisation, optimisation convexe.

Années 2000 : Sac de mots (BoW)

- **BoW textuel** : document = histogramme d'occurrences de mots, puis classifieur SVM.
- **BoW visuel (BoVW)** : dictionnaire visuel construit par clustering de descripteurs locaux (SIFT) extraits de régions d'images.
- État de l'art jusqu'en 2012 : BoW + SVM.

2006 : renouveau du Deep Learning

Hinton et al. proposent un apprentissage non supervisé pour les Deep Belief Nets (DBN), utilisé comme initialisation avant rétropropagation supervisée. Résultats théoriques montrent l'amélioration de la qualité du modèle avec la profondeur.

2010 : percée en reconnaissance vocale

Premier grand succès du DL sur grands jeux de données : *Context-Dependent Pre-trained Deep Neural Networks for Large Vocabulary Speech Recognition* (Dahl et al., 2010).

2012 : la révolution AlexNet

Contexte : ImageNet ILSVRC : 1,2 M images, 1 000 classes. Évaluation : top-5 error.

AlexNet (Krizhevsky et al., 2012) : 60 M paramètres, 650 K neurones, 630 M connexions.

- 5 couches convolutionnelles + 3 couches FC.
- Convolution + ReLU + Pooling.
- Apprentissage sur 2 GPU pendant 1 semaine.
- Améliorations architecturales : ReLU (vs sigmoïde), dropout, data augmentation, overlapping pooling (LRN).

À retenir. AlexNet a la même architecture générale que LeNet, mais bien plus grande (60 M paramètres vs 60 K) : plus de données et GPU rendent possible l'entraînement de grands modèles.

Modules modernes des CNN

Non-linéarités

- **ReLU (Rectified Linear Unit)** : $y = \max(0, x)$. Résout le problème du gradient vanishing, accélère l'apprentissage et la convergence.

- **Leaky ReLU (LReLU)** : $y = \max(\lambda x, x)$ avec λ prédéfini empiriquement.
- **PReLU (Parametric ReLU)** : λ_k appris pendant l'entraînement.
- **RReLU (Randomized ReLU)** : λ échantillonné aléatoirement pendant l'entraînement, fixé au test.
- **ELU (Exponential Linear Unit)** : $y = x$ si $x > 0$, $y = \lambda(e^x - 1)$ sinon.

Data augmentation

Perturbation des images d'entraînement : mirroring, rotation, stretching, shearing, distortion, perturbation de couleur, etc. Augmente la taille de l'ensemble d'entraînement et la robustesse aux variations non pertinentes. Appliquée en train ET en test.

Dropout (Hinton et al., 2012)

- Omission aléatoire de chaque unité cachée avec probabilité 0,5 pendant l'entraînement.
- Technique de régularisation limitant le sur-apprentissage (meilleure généralisation).
- Empêche la co-adaptation : un neurone ne devient utile qu'en présence d'autres neurones spécifiques.
- Interprétation : moyenne sur de nombreux réseaux.
- Au test : toutes les unités sont utilisées mais les poids sont multipliés par 0,5 (approximation de la moyenne géométrique).

Padding

Le **zero-padding** ajoute des zéros autour de l'entrée pour éviter le rétrécissement rapide de la dimension spatiale. Exemple : padding p sur une image $n \times n$ avec filtre $f \times f$ à stride 1 donne une sortie $(n + 2p - f + 1) \times (n + 2p - f + 1)$.

Overlapping pooling

Pooling avec une taille de fenêtre z supérieure au stride s ($z > s$). Utilisé dans AlexNet (LRN).

Outils et bibliothèques

Frameworks disponibles :

- **Caffe / Decaf** : script, non modulaire.
- **MatConvNet** (Matlab) : facile d'utilisation.
- **Torch** (Lua) : efficacité, modularité.
- **TensorFlow / Theano / PyTorch** (Python) : auto-différentiation.
- **Keras** : wrapper haut-niveau sur TensorFlow/Theano.

Exemple Keras : régression logistique sur MNIST

```

1 from keras.models import Sequential
2 from keras.layers import Dense, Activation
3 from keras.optimizers import SGD
4 from keras.datasets import mnist
5
6 model = Sequential()
7 model.add(Dense(10, input_dim=784, name='fc1'))
8 model.add(Activation('softmax'))
9
```

```

10 sgd = SGD(lr=0.5)
11 model.compile(loss='categorical_crossentropy',
12               optimizer=sgd, metrics=['accuracy'])
13
14 (X_train, y_train), (X_test, y_test) = mnist.load_data()
15 # pre-processing ...
16 model.fit(X_train, y_train, batch_size=128,
17           epochs=20, verbose=1)

```

Exemple Keras : CNN

```

1 model = Sequential()
2 model.add(Conv2D(32, kernel_size=5,
3                 activation='sigmoid', input_shape=(28,28,1),
4                 padding='same'))
5 model.add(MaxPooling2D(pool_size=(2, 2)))
6 model.add(Conv2D(64, (5, 5), activation='sigmoid', padding='same'))
7 model.add(MaxPooling2D(pool_size=(2, 2)))
8 model.add(Flatten())
9 model.add(Dense(100, activation='sigmoid'))
10 model.add(Dense(nb_classes, activation='softmax'))

```

Transfert d'apprentissage

Problématique

Les CNN profonds nécessitent de grands jeux de données annotés. Le nombre élevé de paramètres rend l'entraînement *from scratch* difficile sur les petits jeux de données.

Deep Features (transfert pur)

On extrait les activations d'une couche comme vecteur de caractéristiques : **Deep Features** (DF). Ces DF sont utilisées comme descripteurs « off-the-shelf » pour n'importe quelle tâche visuelle.

Fine-tuning

On reprend un modèle pré-entraîné sur ImageNet et on continue l'entraînement (*fine-tuning*) sur le nouveau jeu de données. Meilleure adaptation au domaine cible.

Résultats expérimentaux

Dataset	Taille	Modèle	Perf.
VOC'07 (20 classes)	~5 K ex	From scratch	39,8 mAP
		BoW	61,6 mAP
		Transfert (DF)	83,2 mAP
		Fine-tuning	85,7 mAP
M2CAI'16 (8 classes)	$6 \cdot 10^5$ ex	Transfert	59,3 %
		From scratch	69,1 %
		Fine-tuning	79,1 %

- Petits jeux : transfert (DF) > Bag of Words.
- Jeux moyens : from scratch possible et compétitif.
- Fine-tuning toujours meilleur (petits et grands jeux).

Adaptation de tâche

- **Localisation (R-CNN)** : régions proposées, extraction de DF, classification. Sur VOC'07 : 58,5 mAP (vs 34,3 pour DPM HoG).
- **Segmentation sémantique (FCN)** : architecture encodeur-décodeur avec convolution 1×1 et déconvolution (Chen et al., ICLR'15).

Enjeux actuels et perspectives

Apprentissage non supervisé

Le succès du DL est essentiellement supervisé. Solution : transformer le problème non supervisé en un problème supervisé : **auto-supervision**.

À retenir. **Generative Adversarial Networks (GAN)** (Goodfellow et al., 2014) : jeu à 2 joueurs (générateur vs discriminateur). Le générateur apprend la distribution des données.

Nouvelles tâches en IA

VQA (Visual Question Answering) : répondre à des questions en langage naturel sur une image. Combinaison vision + langage.

Limites actuelles

- Compréhension formelle encore limitée.
- Optimisation non convexe.
- Capacité à démêler les variétés (manifold untangling).
- Robustesse au sur-apprentissage et généralisation.

Conclusion

Le DL a un impact énorme sur les résultats expérimentaux, mais la compréhension théorique et les capacités d'apprentissage non supervisé restent des défis ouverts.

Questions clés (QCM)

1. Quelle année marque la percée des CNN sur ImageNet ?

- (a) 2006
- (b) 2010
- (c) 2012
- (d) 2014

Réponse : c (2012, AlexNet).

2. Quel était l'état de l'art en classification image avant 2012 ?

- (a) Réseaux fully connected
- (b) BoW + SVM
- (c) Réseaux bayésiens
- (d) Forêts aléatoires

Réponse : b (BoW + SVM).

3. Pourquoi les réseaux profonds ont-ils souffert dans les années 90 ?

- (a) Manque de données
- (b) Optimisation non convexe difficile et manque d'interprétabilité
- (c) Matériel trop lent
- (d) Tous les choix précédents

Réponse : d (manque de données, optimisation non convexe, lenteur, manque d'interprétabilité).

4. Quelle fonction d'activation a aidé à résoudre le problème du gradient vanishing ?

- (a) Sigmoid
- (b) Tanh
- (c) ReLU
- (d) Softmax

Réponse : c (ReLU).

5. Quel est le rôle du dropout ?

- (a) Accélérer l'entraînement
- (b) Régulariser pour éviter le sur-apprentissage
- (c) Ajouter du bruit aux données
- (d) Initialiser les poids

Réponse : b (régularisation par omission aléatoire de neurones).

6. Que sont les Deep Features (DF) ?

- (a) Les poids de la dernière couche
- (b) Les activations d'une couche utilisées comme descripteurs
- (c) Les gradients de la fonction de perte
- (d) Les hyper-paramètres du réseau

Réponse : b (activations extraites d'une couche).

7. Quelle méthode donne les meilleures performances sur un jeu de données de taille moyenne (10^5 ex) ?

- (a) Transfert (DF)
- (b) From scratch
- (c) Fine-tuning
- (d) BoW

Réponse : c (fine-tuning).

8. Quel est le principe des GANs ?
- (a) Un seul réseau qui génère des données
 - (b) Un jeu à 2 joueurs : générateur vs discriminateur
 - (c) Un réseau qui segmente des images
 - (d) Un réseau qui traduit des langues

Réponse : b (jeu à 2 joueurs, GAN).

9. Quel score R-CNN a-t-il obtenu sur VOC'07 pour la localisation ?
- (a) 34,3 mAP
 - (b) 58,5 mAP
 - (c) 83,2 mAP
 - (d) 95,7 mAP

Réponse : b (58,5 mAP).

10. Parmi ces éléments, lequel n'est PAS un module moderne des CNN ?
- (a) ReLU
 - (b) Dropout
 - (c) Backpropagation
 - (d) Data augmentation

Réponse : c (backpropagation existe depuis les années 80).

Références

- [1] A. Krizhevsky, I. Sutskever, G. E. Hinton. *ImageNet Classification with Deep Convolutional Neural Networks*. NIPS, 2012.
- [2] G. E. Hinton, S. Osindero, Y.-W. Teh. *A fast learning algorithm for deep belief nets*. Neural Computation, 18(7):1527–1554, 2006.
- [3] G. E. Hinton, N. Srivastava, A. Krizhevsky, I. Sutskever, R. Salakhutdinov. *Improving neural networks by preventing co-adaptation of feature detectors*. arXiv:1207.0580, 2012.
- [4] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, Y. Bengio. *Generative Adversarial Nets*. NIPS, 2014.
- [5] H. Azizpour, A. S. Razavian, J. Sullivan, A. Maki, S. Carlsson. *Factors of transferability for a generic convnet representation*. IEEE TPAMI, 38(9):1790–1802, 2016.