

Analyse critique – ROSE: A Package for Binary Imbalanced Learning

Lunardon, Menardi, Torelli (R Journal, 6(1), 2014)

Package R pour l'apprentissage sur données déséquilibrées

Étudiant STA211

14 juin 2026

Résumé

Cet article présente le package R **ROSE** (Random Over-Sampling Examples), dédié à la classification binaire en présence de classes déséquilibrées. La méthode génère des échantillons artificiels équilibrés par bootstrap lissé, facilitant à la fois l'estimation du modèle et l'évaluation de sa performance. Cette fiche propose une analyse critique structurée, avec illustrations numériques, extraits de code R et QCM.

Table des matières

1	Présentation générale	2
1.1	Contexte	2
1.2	Référence	2
2	Problème du déséquilibre de classes	2
2.1	Conséquences	2
2.2	Remèdes traditionnels	2
3	La méthode ROSE	3
3.1	Algorithme	3
3.2	Propriétés	3
3.3	ROSE pour l'évaluation	3
3.4	Analyse critique	3
4	Illustrations numériques	3
4.1	Données hacide	3
4.2	Résultats comparatifs	4
5	Extraits de code R	5
5.1	Installation et chargement	5
5.2	Arbre naïf (ignorant le déséquilibre)	5
5.3	Sur-échantillonnage (ovun.sample)	5
5.4	Méthode ROSE	5
5.5	ROSE pour l'évaluation	6
5.6	Utilisation d'un classifieur non-standard (k-NN)	6
6	Conclusion	6
	Questions clés (QCM)	7

Présentation générale

Contexte

Les données déséquilibrées (ex. 2% de positifs, 98% de négatifs) posent un problème majeur en classification supervisée. Un classifieur naïf qui prédit toujours la classe majoritaire atteint 98% de bonne classification, mais ne détecte aucun cas rare.

L'article propose le package **ROSE** qui implémente une méthode unifiée pour :

- **Estimer** un classifieur malgré le déséquilibre (via des données artificielles équilibrées)
- **Évaluer** la performance de façon fiable (via des estimateurs spécifiques : holdout, bootstrap, validation croisée)

Référence

- Lunardon N., Menardi G., Torelli N. (2014). *ROSE: A Package for Binary Imbalanced Learning*. The R Journal, 6(1), 79–89.
- Méthode sous-jacente : Menardi G., Torelli N. (2014). *Training and assessing classification rules with imbalanced data*. Data Mining and Knowledge Discovery, 28(1), 92–122.

Problème du déséquilibre de classes

Conséquences

1. **Estimation** : les règles de classification sont «submergées» par la classe majoritaire ; la classe rare est ignorée.
2. **Évaluation** : le taux d'erreur global (accuracy) est trompeur ; on utilise plutôt précision, rappel, F -mesure, ou AUC.
3. **Seuil** : le seuil par défaut ($\hat{p} > 0,5$) peut ne jamais être dépassé ; la courbe ROC évite ce choix arbitraire.

Remèdes traditionnels

- **Sur-échantillonnage** (over) : tirage avec remise dans la classe minoritaire. Risque de sur-ajustement (doublons).
- **Sous-échantillonnage** (under) : tirage sans remise dans la classe majoritaire. Perte d'information.
- **Combinaison** (both) : sur- et sous-échantillonnage simultanés.

TABLE 1 – Impact de l'équilibrage sur l'AUC (hacide, arbre rpart)

Méthode	AUC	Commentaire
Aucun (arbre brut)	0,600	Mauvais, classe rare ignorée
Oversampling	0,798	Amélioration significative
Undersampling	0,749	Moindre que l'over
Both	0,798	Équivalent à l'over
ROSE	0,989	Excellente généralisation

La méthode ROSE

Algorithme

ROSE génère un nouvel exemple artificiel (x^*, y^*) en trois étapes :

1. Choisir $y^* = Y_j$ avec probabilité π_j .
2. Sélectionner (x_i, y_i) tel que $y_i = y^*$, avec probabilité $1/n_j$.
3. Générer $x^* \sim K_{H_j}(\cdot, x_i)$, où K_{H_j} est un noyau centré en x_i de matrice de lissage H_j .

Propriétés

- Équivalent à tirer de l'estimateur à noyau de $f(x|Y_j)$ (densité conditionnelle).
- Quand $H_j \rightarrow 0$, ROSE se réduit à une combinaison over/under-sampling. - Pas de doublons (contrairement au sur-échantillonnage simple).
- Les paramètres de lissage H_0, H_1 sont choisis de façon optimale sous hypothèse de normalité.
- Ajustables via `hmult.majo` et `hmult.mino`.

ROSE pour l'évaluation

ROSE peut être utilisé pour estimer la précision d'un classifieur selon trois schémas :

- **Holdout** : entraînement sur $\mathcal{T}_m^*$ (ROSE), test sur $\mathcal{T}_n$ (original).
- **Bootstrap** : B échantillons ROSE, test sur l'original, distribution bootstrap de la métrique.
- **Leave-K-out CV** : $Q = n/K$ groupes, entraînement ROSE sur $\mathcal{T}_n \setminus \mathcal{T}_i^K$, test sur $\mathcal{T}_i^K$.

Analyse critique

Forces :

- Approche unifiée (estimation + évaluation).
- Pas de doublons, meilleure généralisation.
- Flexible (tout classifieur R standard ou sur mesure).
- Interface bien conçue, documentation claire.

Faiblesses :

- Paramètres de lissage H_j choisis sous hypothèse de normalité (potentiellement sous-optimaux pour d'autres distributions).
- Coût calculatoire pour bootstrap $B = 50$ (50 entraînements + prédictions).
- Pas de parallélisation native.
- Méthode limitée à la classification binaire.
- Holdout ROSE tend à surestimer l'AUC (biais optimiste), mais avec un MSE plus faible qu'un holdout standard.

Illustrations numériques

Données hacide

Les données `hacide` sont fournies avec le package :

- `hacide.train` : $n = 1000$, 2% de positifs (20/980).
- `hacide.test` : $n = 250$.
- 2 variables explicatives x_1, x_2 .
- La classe rare forme un demi-cercle bruité au sein de la classe majoritaire (ellipse normale).

Résultats comparatifs

AUC sur l'échantillon de test hacide.test		
Stratégie	AUC	Écart / base
Arbre brut (déséquilibré)	0,600	—
Arbre + oversampling	0,798	+0,198
Arbre + undersampling	0,749	+0,149
Arbre + both	0,798	+0,198
Arbre + ROSE	0,989	+0,389
ROSE holdout (AUC estimée)	0,985	—
ROSE bootstrap (médiane)	0,984	—
ROSE L5OCV	0,973	—

FIGURE 1 – Performances comparées des stratégies d'équilibrage sur les données hacide (Lunardon et al., 2014)

Extraits de code R

Installation et chargement

```
install.packages("ROSE")
library(ROSE)
data(hacide)
str(hacide.train)
table(hacide.train$cls) # 0: 980, 1: 20
```

Arbre naïf (ignorant le déséquilibre)

```
library(rpart)
treeimb <- rpart(cls ~ ., data = hacide.train)
pred.treeimb <- predict(treeimb, newdata = hacide.test)

# Metriques
accuracy.meas(hacide.test$cls, pred.treeimb[,2])
# precision: 1.000, recall: 0.200, F: 0.167

roc.curve(hacide.test$cls, pred.treeimb[,2], plotit = FALSE)
# AUC: 0.600
```

Sur-échantillonnage (ovun.sample)

```
# Oversampling
data.bal.ov <- ovun.sample(cls ~ ., data = hacide.train,
                           method = "over", p = 0.5, seed = 1)$data
table(data.bal.ov$cls)

# Undersampling
data.bal.un <- ovun.sample(cls ~ ., data = hacide.train,
                           method = "under", p = 0.5, seed = 1)$data
table(data.bal.un$cls)

# Combinaison
data.bal.ou <- ovun.sample(cls ~ ., data = hacide.train,
                           method = "both", N = 1000, p = 0.5,
                           seed = 1)$data
table(data.bal.ou$cls)
```

Méthode ROSE

```
# Generation de donnees equilibrees
data.rose <- ROSE(cls ~ ., data = hacide.train, seed = 1)$data
table(data.rose$cls)

# Ajustement et prediction
tree.rose <- rpart(cls ~ ., data = data.rose)
pred.tree.rose <- predict(tree.rose, newdata = hacide.test)
roc.curve(hacide.test$cls, pred.tree.rose[,2])
# AUC: 0.989

# Ajustement des parametres de lissage
data.rose.h <- ROSE(cls ~ ., data = hacide.train, seed = 1,
                    hmult.majo = 0.25, hmult.mino = 0.5)$data
```

ROSE pour l'évaluation

```
# Holdout ROSE
ROSE.holdout <- ROSE.eval(cls ~ ., data = hacide.train,
  learner = rpart, method.assess = "holdout",
  extr.pred = function(obj) obj[,2], seed = 1)
# AUC: 0.985

# Bootstrap ROSE (B=50)
ROSE.boot <- ROSE.eval(cls ~ ., data = hacide.train,
  learner = rpart, method.assess = "BOOT", B = 50,
  extr.pred = function(obj) obj[,2], seed = 1)
summary(ROSE.boot)
# Mediane AUC: 0.984

# L5OCV ROSE
ROSE.l5ocv <- ROSE.eval(cls ~ ., data = hacide.train,
  learner = rpart, method.assess = "LKOCV", K = 5,
  extr.pred = function(obj) obj[,2], seed = 1)
# L5OCV AUC: 0.973
```

Utilisation d'un classifieur non-standard (k-NN)

```
library(class)
knn.wrap <- function(data, newdata, ...) {
  knn(train = data[, -1], test = newdata, cl = data[, 1], ...)
}

rose.holdout.knn <- ROSE.eval(cls ~ ., data = hacide.train,
  learner = knn.wrap, control.learner = list(k = 2, prob = TRUE),
  method.assess = "holdout", seed = 1)
```

Conclusion

Le package **ROSE** est un outil complet et bien conçu pour la classification binaire sur données déséquilibrées. Ses points forts :

- Méthode unifiée couvrant estimation et évaluation.
- Génération de données artificielles sans doublons (bootstrap lissé).
- Interface souple acceptant tout classifieur R.
- Plusieurs méthodes d'évaluation (holdout, bootstrap, CV).

Ses limites :

- Classification binaire uniquement.
- Paramétrisation du noyau sous hypothèse de normalité.
- Coût calculatoire non négligeable (surtout bootstrap).
- Légère surestimation de l'AUC en holdout.

Note : Depuis 2014, d'autres packages ont émergé (**themis** pour le tidyverse, **smotefamily**, **UBL**), mais ROSE reste une solution de référence, pédagogique et robuste.

Questions clés (QCM)

1. Quel est le principal problème posé par les données déséquilibrées en classification ?

- (a) Le modèle converge trop vite
- (b) La classe rare est ignorée par le classifieur
- (c) Les variables explicatives sont corrélées
- (d) L'AUC est toujours de 0,5

Réponse : b.

2. Dans l'exemple hacide, quel est le pourcentage d'exemples positifs dans l'échantillon d'apprentissage ?

- (a) 10%
- (b) 5%
- (c) 2%
- (d) 20%

Réponse : c ($20/1000 = 2\%$).

3. Quelle est la principale différence entre ROSE et le sur-échantillonnage simple ?

- (a) ROSE est plus lent
- (b) ROSE génère des données synthétiques sans doublons
- (c) ROSE nécessite la library caret
- (d) ROSE ne fonctionne qu'avec rpart

Réponse : b.

4. Dans l'algorithme ROSE, à quoi correspond la matrice H_j ?

- (a) À la matrice de covariance des données
- (b) À la matrice de lissage du noyau
- (c) À la matrice des poids du classifieur
- (d) À la matrice de confusion

Réponse : b.

5. Quelle AUC obtient-on avec un arbre de décision (**rpart**) entraîné sur des données équilibrées par ROSE (données hacide) ?

- (a) 0,600
- (b) 0,798
- (c) 0,989
- (d) 0,500

Réponse : c.

6. Quelle fonction du package ROSE permet d'obtenir une estimation de l'AUC par validation croisée ?

- (a) `ROSE()`
- (b) `ovun.sample()`
- (c) `ROC.eval()`
- (d) `ROSE.eval()`

Réponse : d.

7. Quelle est la métrique d'évaluation recommandée par les auteurs pour éviter le choix arbitraire d'un seuil ?

- (a) Le F -mesure
- (b) La précision
- (c) Le rappel

(d) L'AUC (aire sous la courbe ROC)

Réponse : d.

8. Quel argument permet de réduire la largeur du noyau dans `ROSE()` ?

(a) `hmult.majo` et `hmult.mino`

(b) `kernel.width`

(c) `smoothing.factor`

(d) `bandwidth`

Réponse : a.

9. Que se passe-t-il quand $H_j \rightarrow 0$ dans la méthode ROSE ?

(a) La méthode diverge

(b) ROSE se réduit à over/under-sampling standard

(c) Le noyau devient gaussien

(d) AUC devient 1

Réponse : b.

10. Selon l'article, comment peut-on adapter un classifieur non-standard (ex. `knn`) pour l'utiliser dans `ROSE.eval()` ?

(a) Ce n'est pas possible

(b) En écrivant une fonction wrapper avec arguments `data` et `newdata`

(c) En modifiant le code source de ROSE

(d) En utilisant `caret::train` à la place

Réponse : b.

Références

- [1] N. Lunardon, G. Menardi, N. Torelli. *ROSE: A Package for Binary Imbalanced Learning*. The R Journal, 6(1):79–89, 2014.
- [2] G. Menardi, N. Torelli. *Training and assessing classification rules with imbalanced data*. Data Mining and Knowledge Discovery, 28(1):92–122, 2014.
- [3] N. V. Chawla, K. W. Bowyer, L. O. Hall, W. P. Kegelmeyer. *SMOTE: Synthetic Minority Over-sampling Technique*. J. Artif. Intell. Res., 16:321–357, 2002.
- [4] L. Torgo. *Data Mining with R, Learning with Case Studies*. Chapman & Hall/CRC, 2010.