

Analyse multi-blocs

STA211 — Apprentissage non supervisé — Fiche récapitulative
8 juin 2026

Table des matières

1	Présentation	2
2	Phases de l'analyse multi-blocs	2
3	Méthodes	2
3.1	Double ACP (DACP)	2
3.2	STATIS	3
3.3	AFM (Analyse Factorielle Multiple)	3
4	Exemple numérique : DACP sur les données de criminalité	3
4.1	Données	3
4.2	Phase 1 : Interstructure	3
4.3	Phase 2 : Compromis et Intrastructure	4
4.4	Phase 3 : Trajectoires	4
5	Code Python	4
6	Code R	6

1 Présentation

L'**analyse multi-blocs** regroupe un ensemble de méthodes factorielles permettant d'analyser simultanément plusieurs tableaux de données décrivant les mêmes individus (ou les mêmes variables). Chaque tableau est appelé un **bloc**.

Contexte typique : On dispose de N tableaux $\mathbf{X}_1, \dots, \mathbf{X}_N$, tous avec les mêmes n individus en lignes, mais avec possiblement des variables différentes en colonnes ($p_1, \dots, p_N$).

Exemple : Pour chaque département français, on dispose du nombre de crimes et délits dans 9 catégories, pour chaque année de 1974 à 1993. Chaque année est un **bloc** de 9 variables.

Objectifs :

- Comparer les groupes de variables entre eux
- Dégager une structure commune (compromis)
- Visualiser l'évolution des individus (trajectoires)
- Réduire la dimension

2 Phases de l'analyse multi-blocs

Toute analyse multi-blocs se décompose en **4 phases** :

1. **Interstructure** : chaque tableau est résumé par un objet (centre de gravité, matrice de produits scalaires...). On compare ces objets entre eux (ex. ACP sur les centres de gravité).
2. **Compromis** : on recherche un espace commun qui résume l'ensemble des tableaux (maximisation de l'inertie projetée de tous les nuages).
3. **Intrastructure** : on analyse le compromis (cercles des corrélations, contributions...) pour décrire finement les ressemblances entre tableaux.
4. **Trajectoires** : on projette les individus de chaque tableau dans le plan du compromis pour visualiser leur évolution.

3 Méthodes

3.1 Double ACP (DACP)

Quand l'utiliser ? Mêmes variables mesurées sur les mêmes individus à des instants différents ($p_t = p$ pour tout t , n identique).

Principe :

1. **Interstructure** : ACP sur les centres de gravité $\bar{\mathbf{x}}_t$ de chaque tableau (dimension $N \times p$). Chaque année est un point dans $\mathbb{R}^p$.
2. **Compromis** : on cherche les axes $\mathbf{v}_k$ maximisant la somme des inerties de projection de tous les nuages :

$$\max_{\mathbf{v}_1, \dots, \mathbf{v}_q} \sum_{t=1}^N \sum_{k=1}^q \mathbf{v}_k' \mathbf{V}_t \mathbf{v}_k$$

où $\mathbf{V}_t$ est la matrice de variance-covariance du tableau t . Ceci revient à une ACP sur la matrice de variance-covariance **compromis** :

$$\mathbf{V} = \sum_{t=1}^N \mathbf{V}_t$$

3. **Intrastructure** : ACP sur les N tableaux centrés concaténés verticalement (dimension $Nn \times p$). Les axes sont les mêmes que ceux du compromis.
4. **Trajectoires** : projection des individus de chaque année dans le plan factoriel.

3.2 STATIS

Quand l'utiliser ? Mêmes individus, variables différentes selon les blocs (ou l'inverse pour STATIS duale).

Principe : On ne peut plus comparer les centres de gravité (variables différentes). On utilise les **matrices de produits scalaires** $\mathbf{W}_t = \mathbf{X}_t \mathbf{M}_t \mathbf{X}_t^\top$ de dimension $n \times n$, qui représentent les proximités entre individus pour chaque bloc.

1. **Interstructure** : ACP sur l'espace des matrices $\mathbf{W}_t$ (produit scalaire de Hilbert-Schmidt).
2. **Compromis** : combinaison linéaire optimale $\mathbf{W}_{\text{comp}} = \sum_{t=1}^N a_t \mathbf{W}_t$.
3. **Intrastructure** : diagonalisation de $\mathbf{W}_{\text{comp}}$ (équivalente à une ACP).

3.3 AFM (Analyse Factorielle Multiple)

Quand l'utiliser ? Mêmes individus, variables de types potentiellement différents (quantitatives, qualitatives). Elle équilibre le poids de chaque bloc en pondérant par la première valeur propre de l'ACP (ou ACM) de chaque bloc.

4 Exemple numérique : DACP sur les données de criminalité

4.1 Données

$n = 94$ départements français, $p = 9$ variables de criminalité mesurées chaque année de 1974 à 1993 ($N = 20$ tableaux).

Variables :

VO : vols et recels	FX : faux et escroqueries
DF : délits financiers	CH : chèques sans provision
CR : coups et règlements de comptes	DD : destructions et dégradations
ET : délits à la police des étrangers	ST : stupéfiants

4.2 Phase 1 : Interstructure

On calcule le centre de gravité de chaque année (vecteur de dimension 9), puis on effectue une ACP sur le tableau 20×9 centré.

Axe	Valeur propre	% inertie cumulé
1	6,83	75,9%
2	1,69	94,7%
3	0,24	97,4%

Le premier plan explique **94,7%** de l'inertie : les années sont très bien représentées.

Cercle des corrélations (interstructure) :

- Axe 1 : corrélé positivement avec VO, DD, ET, FX, CR, ST — « effet taille » de la criminalité.
- Axe 2 : lié à CH et DF — oppose la criminalité financière au reste.

Plan des individus (années) : Les années s'alignent le long de l'axe 1, révélant une **évolution temporelle quasi linéaire** : la criminalité (VO, ST, ET, FX, CR, DD) a augmenté entre 1974 et 1993. Les années 1974–1978 sont stables, 1979–1988 montrent une forte progression, et 1989–1993 se stabilisent à un niveau élevé.

4.3 Phase 2 : Compromis et Intrastructure

On concatène les 20 tableaux centrés verticalement (matrice $20 \times 94 \times 9$, soit 1880×9) et on effectue une ACP.

Axe	Valeur propre	% inertie
1	4,18	32,2%
2	2,36	18,2%
3	1,93	14,9%

Interprétation :

- Axe 1 : oppose la criminalité contre les biens (VO, DD, CH) à la criminalité contre les personnes.
- Axe 2 : oppose criminalité financière (DF, FX) à la délinquance de voie publique.

4.4 Phase 3 : Trajectoires

On projette les individus (départements) de chaque année dans le plan 1–2 du compromis. On obtient des **trajectoires** qui montrent l'évolution de chaque département au cours du temps.

5 Code Python

```

1 import numpy as np
2 import pandas as pd
3 from sklearn.decomposition import PCA
4 from sklearn.preprocessing import StandardScaler
5
6 def dacp(list_of_dfs, n_components=2):
7     """
8     Double ACP sur une liste de DataFrames (meme variables, meme individus).
9     Chaque DF = un bloc (ex. une annee).
10    """
11    n_blocs = len(list_of_dfs)
12    p = list_of_dfs[0].shape[1] # nombre de variables
13
14    # --- Phase 1 : Interstructure ---
15    # Centres de gravite de chaque bloc
16    centers = np.array([df.mean(axis=0).values for df in list_of_dfs])
17    centers_scaled = StandardScaler(with_std=False).fit_transform(centers)
18
19    pca_inter = PCA()
20    pca_inter.fit(centers_scaled)
21
22    # --- Phase 2 : Compromis ---
23    # Matrice de variance-covariance compromis
24    V_sum = np.zeros((p, p))
25    for df in list_of_dfs:
26        df_centered = df - df.mean(axis=0)
27        V_sum += df_centered.T @ df_centered / (len(df) - 1)
28    V_sum /= n_blocs # moyenne des matrices de covariance
29
30    # ACP sur V_sum
31    eigvals, eigvecs = np.linalg.eigh(V_sum)
32    idx = np.argsort(eigvals)[::-1]
33    eigvals = eigvals[idx]
34    eigvecs = eigvecs[:, idx]
35
36    # --- Phase 3 : Intrastructure ---
37    # Concaténation verticale des tableaux centres
38    all_centered = np.vstack([df - df.mean(axis=0) for df in list_of_dfs])
39    scores = all_centered @ eigvecs[:, :n_components]
40
41    # --- Phase 4 : Trajectoires ---

```

```
42 n_individuals = list_of_dfs[0].shape[0]
43 trajectories = np.zeros((n_individuals, n_blocs, n_components))
44 for t, df in enumerate(list_of_dfs):
45     centered = df - df.mean(axis=0)
46     trajectories[:, t, :] = centered @ eigvecs[:, :n_components]
47
48     return {
49         'pca_inter': pca_inter,
50         'eigvals': eigvals,
51         'eigvecs': eigvecs,
52         'scores': scores,
53         'trajectories': trajectories
54     }
55
56 # Exemple d'utilisation
57 if __name__ == "__main__":
58     # Simulation de 3 blocs (annees) avec 10 individus et 4 variables
59     np.random.seed(42)
60     blocs = [pd.DataFrame(np.random.randn(10, 4) + t*0.1)
61              for t in range(3)]
62     res = dacp(blocs)
63     print("Valeurs propres :", res['eigvals'][:3])
```

Listing 1 – DACP avec scikit-learn

```

1 # pip install prince
2
3 import pandas as pd
4 from prince import MFA
5
6 # Construction du jeu de donnees multi-blocs
7 # Simulons 2 blocs de variables
8 np.random.seed(123)
9 n = 50
10 bloc1 = pd.DataFrame({
11     'V1': np.random.randn(n),
12     'V2': np.random.randn(n),
13     'V3': np.random.randn(n)
14 }, index=[f'I{i}' for i in range(n)])
15
16 bloc2 = pd.DataFrame({
17     'V4': np.random.randn(n),
18     'V5': np.random.randn(n)
19 }, index=[f'I{i}' for i in range(n)])
20
21 # Concaténation
22 X = pd.concat([bloc1, bloc2], axis=1)
23
24 # Groupes
25 groups = [3, 2] # 3 var dans bloc1, 2 dans bloc2
26
27 # AFM
28 mfa = MFA(groups=groups, n_components=3)
29 mfa.fit(X)
30
31 # Résultats
32 print("Valeurs propres :", mfa.eigenvalues_)
33 print("Coordonnées des individus :")
34 print(mfa.row_coordinates(X).head())

```

Listing 2 – AFM avec prince

6 Code R

```

1 # install.packages("FactoMineR")
2 library(FactoMineR)
3
4 # Simulation de 3 blocs (annees)
5 set.seed(42)
6 n <- 10 # individus
7 p <- 4 # variables
8 blocs <- list(
9     data.frame(matrix(rnorm(n*p) + 0.1, n, p)),
10    data.frame(matrix(rnorm(n*p) + 0.2, n, p)),
11    data.frame(matrix(rnorm(n*p) + 0.3, n, p))
12 )
13
14 # Concaténation verticale pour DACP
15 X_all <- do.call(rbind, blocs)
16
17 # Variable indiquant le bloc
18 bloc_labels <- rep(1:3, each = n)
19
20 # DACP manuelle
21 centers <- t(apply(blocs, colMeans)) # centres de gravite
22 pca_inter <- PCA(centers, graph = FALSE)
23 print(pca_inter$eig)
24
25 # Compromis

```

```
26 V_sum <- Reduce(`+`, lapply(blocs, cov))
27 eig <- eigen(V_sum)
28 print(eig$values[1:3])
```

Listing 3 – DACP avec R

```
1 library(FactoMineR)
2
3 # Jeu de donnees : meme structure
4 n <- 50
5 bloc1 <- data.frame(
6   V1 = rnorm(n), V2 = rnorm(n), V3 = rnorm(n)
7 )
8 bloc2 <- data.frame(
9   V4 = rnorm(n), V5 = rnorm(n)
10 )
11 X <- cbind(bloc1, bloc2)
12
13 # AFM
14 res.afm <- MFA(X, group = c(3, 2),
15               type = c("s", "s"),
16               name.group = c("Bloc1", "Bloc2"),
17               graph = FALSE)
18
19 # Valeurs propres
20 print(res.afm$eig)
21
22 # Cercle des correlations
23 plot(res.afm, choix = "var")
24
25 # Carte des individus
26 plot(res.afm, choix = "ind")
27
28 # Representations partielles
29 plot(res.afm, choix = "axes")
```

Listing 4 – AFM avec FactoMineR

QCM — Vérifiez vos connaissances

Pour chaque question, choisissez la bonne réponse. Les réponses sont en page 10.

1. Que signifie l'acronyme **DACP** ?
 - (a) Double Analyse en Composantes Principales
 - (b) Discrimination par Analyse en Composantes Principales
 - (c) Décomposition en Axes Canoniques Principaux
 - (d) Analyse Dynamique en Composantes Principales
2. Combien de phases comporte une analyse multi-blocs ?
 - (a) 2
 - (b) 3
 - (c) 4
 - (d) 5
3. La phase d'**interstructure** consiste à :
 - (a) analyser la structure interne de chaque bloc séparément
 - (b) comparer les blocs entre eux via leurs centres de gravité ou matrices de produits scalaires
 - (c) calculer les trajectoires des individus
 - (d) effectuer une classification hiérarchique
4. Dans la DACP, la matrice de variance-covariance **compromis** $\mathbf{V}$ s'obtient par :
 - (a) $\mathbf{V} = \sum_{t=1}^N \mathbf{V}_t$
 - (b) $\mathbf{V} = \prod_{t=1}^N \mathbf{V}_t$
 - (c) $\mathbf{V} = \frac{1}{N} \sum_{t=1}^N \mathbf{V}_t$
 - (d) $\mathbf{V} = \sum_{t=1}^N \mathbf{V}_t^{-1}$
5. La méthode **STATIS** utilise pour l'interstructure :
 - (a) les centres de gravité de chaque tableau
 - (b) les matrices de produits scalaires $\mathbf{W}_t = \mathbf{X}_t \mathbf{M}_t \mathbf{X}_t^\top$
 - (c) les matrices de corrélation
 - (d) les valeurs propres de chaque tableau
6. La DACP s'applique quand :
 - (a) les individus sont différents d'un tableau à l'autre
 - (b) les variables sont différentes d'un tableau à l'autre
 - (c) les mêmes variables sont mesurées sur les mêmes individus
 - (d) les données sont qualitatives
7. L'**AFM** (Analyse Factorielle Multiple) pondère chaque bloc par :
 - (a) la somme de ses valeurs propres
 - (b) l'inverse de sa première valeur propre
 - (c) le nombre de variables du bloc
 - (d) le nombre d'individus
8. Dans la DACP sur les données de criminalité, le premier axe de l'interstructure représente :
 - (a) l'opposition entre crimes violents et délits financiers
 - (b) un effet taille de la criminalité qui augmente avec le temps
 - (c) la différence entre zones urbaines et rurales
 - (d) la saisonnalité des crimes
9. La phase de **trajectoires** permet de :
 - (a) visualiser l'évolution de chaque individu au fil des blocs

- (b) tracer la frontière entre clusters
 - (c) estimer la qualité de la représentation
 - (d) déterminer le nombre optimal d'axes
10. Quel package R permet de réaliser une AFM ?
- (a) ggplot2
 - (b) FactoMineR
 - (c) kohonen
 - (d) randomForest

Réponses au QCM

N° Explication	Réponse
1 DACP = Double Analyse en Composantes Principales.	a
2 Les 4 phases sont : interstructure, compromis, intrastructure, trajectoires.	c
3 L'interstructure compare les blocs (via centres de gravité pour DACP, matrices $\mathbf{W}_t$ pour STATIS).	b
4 $\mathbf{V} = \sum_{t=1}^N \mathbf{V}_t$ (somme des matrices de variance-covariance de chaque bloc).	a
5 STATIS utilise $\mathbf{W}_t = \mathbf{X}_t \mathbf{M}_t \mathbf{X}_t^\top$ (matrices $n \times n$).	b
6 DACP : mêmes variables ($p_t = p$) sur les mêmes n individus.	c
7 L'AFM pondère chaque bloc par $1/\lambda_1^{(t)}$ (inverse de la 1 ^{ère} valeur propre).	b
8 Axe 1 = effet taille (corrélation avec VO, DD, ET, FX, CR, ST), croissance temporelle.	b
9 Les trajectoires projettent les individus de chaque bloc dans le plan compromis.	a
10 FactoMineR (fonction MFA) implémente l'AFM.	b

Fin de la fiche.