

Fiche récapitulative – STA211

Gestion des données manquantes

10 juin 2026

Résumé

Cette fiche synthétise le cours sur la gestion des données manquantes (V. Audigier, N. Niang). Les données manquantes sont omniprésentes en data-mining : questionnaires incomplets, fusion de fichiers, défaillances de saisie, etc. Leur traitement est indispensable car la plupart des méthodes d'analyse ne sont pas conçues pour les données incomplètes.

Table des matières

1	Introduction	2
2	Mécanismes de manquance	2
2.1	MCAR (Missing Completely At Random)	2
2.2	MAR (Missing At Random)	2
2.3	MNAR (Missing Not At Random)	3
3	Identification des mécanismes	3
4	Traitement par imputation simple	3
4.1	Typologie des méthodes	3
4.2	Imputation séquentielle (plusieurs variables)	4
4.3	Validation du modèle d'imputation	4
4.4	Modèles joints	4
5	Imputation multiple – MICE	4
5.1	Règles de Rubin	5
5.2	Overimputation	5
6	Autres méthodes de traitement	5
6.1	Algorithmes EM et DA	5
6.2	Méthodes par pondération	5
7	Code R – Exemples	5
	Questions clés (QCM)	7

Introduction

Les données manquantes constituent un problème incontournable dans l'application des techniques de data-mining. L'augmentation de la taille des données fait mécaniquement augmenter la probabilité d'en rencontrer.

Les causes sont multiples :

- Oubli de saisie, questionnaires partiellement remplis
- Refus de répondre (questions sensibles : revenus, consommation, etc.)
- Fusion de jeux de données : concaténer des fichiers fait apparaître des blocs verticaux de données manquantes car les variables diffèrent.

Deux approches :

1. Pré-traitement pour se ramener à des données complètes (imputation)
2. Méthodes avancées qui s'appliquent directement sur les données incomplètes (EM, pondération)

La méthode naïve consistant à supprimer les individus incomplets (*liste-wise deletion*) n'est pas satisfaisante :

- Les individus complets ne sont pas nécessairement représentatifs → biais.
- Le nombre d'individus complets devient vite très petit quand le nombre de variables est grand.

Exemple : si 5% des valeurs sont manquantes pour chaque variable (MCAR), un jeu de 50 variables contient en moyenne seulement 8% d'individus complets.

Mécanismes de manquant

On note $\mathbf{X}_{n \times p}$ le tableau de données complet (fictif) et $\mathbf{R}_{n \times p}$ la matrice d'indication de manquant : $r_{ij} = 1$ si x_{ij} est observé, 0 sinon.

Les méthodes employées pour gérer les données manquantes sont conditionnées par le type de mécanisme.

MCAR (Missing Completely At Random)

La probabilité de manquant est indépendante de toutes les données (observées et manquantes) :

$$P(R | X) = P(R).$$

Propriété : les individus complets forment un sous-échantillon représentatif. L'analyse sur les cas complets n'est pas biaisée, mais la variance des estimateurs est augmentée.

Exemple : questionnaire perdu aléatoirement.

MAR (Missing At Random)

La probabilité de manquant dépend des données observées mais pas des données manquantes :

$$P(R | X) = P(R | X^{\text{obs}}).$$

Propriété : l'analyse par cas complets est biaisée. MAR est l'hypothèse par défaut de la plupart des méthodes d'imputation.

Exemple : enquête de satisfaction : seules les personnes insatisfaites en janvier sont réinterrogées en février. La manquant en février dépend de la réponse observée en janvier.

À retenir. L'hypothèse MAR est non testable. Il est recommandé d'inclure des **variables auxiliaires** (peu/pas de manquantes, sans intérêt scientifique propre) qui aident à expliquer la manquant et rendent MAR plus crédible.

MNAR (Missing Not At Random)

La probabilité de manquant dépend des données manquantes elles-mêmes :

$$P(R | X) = P(R | X^{\text{obs}}, X^{\text{mis}}).$$

Exemple : les personnes à haut revenu ne déclarent pas leur revenu.

Traitement : méthodes spécifiques (pattern mixture models, selection models), moins développées et plus complexes que pour MAR.

Identification des mécanismes

Bien qu'il soit impossible de *démontrer* le mécanisme, l'analyse exploratoire aide à l'identifier :

1. **Analyse univariée du dispositif R** : proportion de manquantes par variable.
2. **Analyse bivariée** : lien entre la manquant d'une variable et les valeurs observées d'autres variables. Exemple : distribution de *Credit Amount* selon que *Duration* est observée ou non.
3. **Analyse multivariée** : régression logistique de la manquant sur les variables observées.

Remarque. Ces analyses ne permettent pas de trancher entre MAR et MNAR (tous deux peuvent produire des différences de distribution). Seule la connaissance du mécanisme de production des données permet de décider.

Traitement par imputation simple

L'imputation simple remplace chaque valeur manquante par une valeur plausible (une seule valeur par cellule).

Typologie des méthodes

Imputation marginale (univariée) : moyenne, médiane, tirage aléatoire dans les valeurs observées. **Inconvénient** : détruit les relations entre variables.

Imputation par régression :

1. Ajuster un modèle de régression sur les données observées.
2. Prédire les valeurs manquantes à partir de ce modèle.
3. Ajouter une perturbation aléatoire (**imputation stochastique**) pour mieux respecter la distribution.

Imputation par k plus proches voisins (k -NN) :

1. Identifier les k individus complets les plus proches de l'individu à imputer (distance euclidienne).
2. Tirer une valeur parmi leurs k valeurs observées (ou faire la moyenne).

Choix du modèle :

« Choisir des modèles d'imputation au moins aussi complexes que la méthode qui sera appliquée sur les données imputées » (Schafer, 2003).

Si l'analyse finale comporte des interactions, l'imputation doit les préserver.

Imputation séquentielle (plusieurs variables)

Algorithme :

1. Ordonner les variables de la moins manquante à la plus manquante.
2. Initialiser les valeurs manquantes (tirage dans les observées).
3. Pour chaque variable j (dans l'ordre) :
 - Ajuster le modèle d'imputation de X_j sur les autres variables (données observées de X_j uniquement).
 - Mettre à jour les valeurs imputées de X_j avec ce modèle.
4. Répéter l'étape 3 jusqu'à convergence (stabilisation de la distribution imputée).

Les logiciels proposent des modèles par défaut selon la nature des variables (régression linéaire pour quantitative, logistique pour binaire, etc.).

Validation du modèle d'imputation

Comparer les distributions des données imputées et observées :

- Une différence de **tendance centrale** est attendue sous MAR.
- Une différence de **forme** indique un modèle mal adapté.

Outils : histogrammes superposés, boxplots, analyses bivariées/multivariées.

Modèles joints

Alternative aux approches séquentielles : spécifier un modèle pour la distribution **jointe** de toutes les variables.

- **Données quantitatives** : modèle gaussien multivarié (package **Amelia**).
- **Données qualitatives** : modèle log-linéaire, classes latentes (package **cat**).
- **Données mixtes** : *general location model* (package **mix**).
- **Imputation par analyse factorielle** : ACP, ACM, AFDM (package **missMDA**). Particulièrement adapté à la grande dimension, la multicollinéarité et les données mixtes.

Avantage : rapidité (toutes les variables imputées simultanément). Inconvénient : moins flexible que l'approche séquentielle.

Imputation multiple – MICE

L'imputation simple ignore l'incertitude sur les valeurs imputées : les intervalles de confiance construits après imputation simple ont un taux de couverture trop faible.

L'**imputation multiple** génère M tableaux imputés (typiquement $M \geq 3$, souvent $M = 5$ ou $M = 20$) :

1. Générer M jeux de paramètres du modèle d'imputation (par bootstrap ou tirage dans la distribution a posteriori).
2. Pour chaque jeu, imputer les données $\rightarrow M$ tableaux complets.
3. Appliquer la méthode d'analyse sur chaque tableau.
4. Agréger les M résultats avec les **règles de Rubin**.

Règles de Rubin

Soit $\hat{\theta}_m$ l'estimation du paramètre d'intérêt sur le m -ième tableau imputé, et $\widehat{\text{Var}}(\hat{\theta}_m)$ sa variance estimée.

Estimation agrégée :

$$\hat{\theta} = \frac{1}{M} \sum_{m=1}^M \hat{\theta}_m.$$

Variance totale :

$$\widehat{\text{Var}}(\hat{\theta}) = \frac{1}{M} \sum_{m=1}^M \widehat{\text{Var}}(\hat{\theta}_m) + \left(1 + \frac{1}{M}\right) \frac{1}{M-1} \sum_{m=1}^M (\hat{\theta}_m - \hat{\theta})^2.$$

Le premier terme est la **variance intra-imputation** (incertitude dans chaque échantillon), le second la **variance inter-imputation** (incertitude due aux données manquantes).

Remarque. Les règles de Rubin s'appliquent essentiellement aux modèles linéaires généralisés (régression linéaire, logistique, ANOVA). Pour d'autres méthodes, l'agrégation peut être difficile.

Overimputation

Technique de validation : générer des valeurs plausibles également pour les **données observées**. En générant plusieurs centaines de tableaux, on construit un intervalle de prédiction à 95 % pour chaque valeur observée. Si le modèle est bien choisi, 95 % des valeurs observées sont contenues dans leur intervalle.

Autres méthodes de traitement

Algorithmes EM et DA

- **EM (Expectation-Maximization)** : alterne imputation (espérance) et estimation des paramètres par maximum de vraisemblance.
- **DA (Data Augmentation)** : version bayésienne qui alterne génération des données imputées et tirage des paramètres dans leur distribution a posteriori.

Différence avec l'imputation : le modèle d'imputation est le même que le modèle d'analyse. On ne peut pas, par exemple, imputer par k -NN et analyser par régression linéaire (contrairement à l'imputation).

Méthodes par pondération

Attribuer un poids aux individus complets, inversement proportionnel à leur probabilité d'être manquants. Issu de la théorie des sondages.

Avantage : pas besoin de modéliser la distribution des données. **Inconvénient** : nécessite de modéliser le mécanisme de manquant (estimation difficile des poids en pratique).

Code R – Exemples

Listing 1 – Imputation multiple avec mice

```
1 library(mice)
2
3 # Chargement et inspection
4 data(nhanes)
5 md.pattern(nhanes)
```

```

6
7 # Imputation multiple
8 imp <- mice(nhanes, m = 5, method = 'pmm',
9           seed = 123, printFlag = FALSE)
10
11 # Convergence
12 plot(imp)
13
14 # Comparaison distributions
15 densityplot(imp)
16
17 # Analyse et combinaison
18 fit <- with(imp, lm(bmi ~ age + chl))
19 pooled <- pool(fit)
20 summary(pooled)

```

Listing 2 – Imputation par forêts aléatoires (randomForest)

```

1 library(mice)
2 imp_rf <- mice(nhanes, m = 5,
3               method = 'rf', # random forest
4               seed = 123, printFlag = FALSE)
5 fit_rf <- with(imp_rf, lm(bmi ~ age + chl))
6 summary(pool(fit_rf))

```

Listing 3 – Imputation par analyse factorielle (missMDA)

```

1 library(missMDA)
2 data(ozone)
3
4 # Estimation du nombre de composantes
5 nb <- estim_ncpPCA(ozone[, -1], ncp.max = 5)
6
7 # Imputation par ACP
8 res.impute <- imputePCA(ozone[, -1], ncp = nb$ncp)
9 head(res.impute$completeObs)

```

Listing 4 – Imputation avec Amelia (modèle gaussien)

```

1 library(Amelia)
2 data(freetrade)
3 amelia_out <- amelia(freetrade, m = 5,
4                    ts = 'year', cs = 'country')
5 summary(amelia_out)

```

Listing 5 – Codes pour simuler l'impact de l'imputation simple

```

1 set.seed(123)
2 nsim <- 2000
3 res <- matrix(NA, nsim, 2)
4
5 for (ii in 1:nsim) {
6   x <- rnorm(500)
7   y <- 2 * x + rnorm(500, sd = 0.5)
8
9   # Ajout de donnees manquantes MAR
10  prob <- pnorm(1.2 * x - 0.5)
11  ismar <- sapply(prob,
12                FUN = function(p) sample(c(TRUE, FALSE), 1,
13                                     prob = c(p, 1 - p)))
14  ymar <- y; ymar[ismar] <- NA

```

```
15
16 # Imputation simple par regression stochastique
17 res.lm <- lm(yvar[!isvar] ~ x[!isvar])
18 ystoch <- yvar
19 ystoch[isvar] <- cbind(1, x[isvar]) %*%
20   res.lm$coefficients +
21   rnorm(sum(isvar), sd = summary(res.lm)$sigma)
22
23 # Intervalle de confiance
24 se <- sd(ystoch) / sqrt(500)
25 ci_inf <- mean(ystoch) - qt(0.975, 499) * se
26 ci_sup <- mean(ystoch) + qt(0.975, 499) * se
27 res[ii, ] <- c(mean(ystoch), 0 >= ci_inf & 0 <= ci_sup)
28 }
29
30 # Taux de couverture (devrait etre < 0.95)
31 cat("Taux de couverture moyen:",
32     mean(res[, 2]), "\n")
```

Questions clés (QCM)

1. Le mécanisme MAR signifie que la probabilité de manquant :

- (a) Est indépendante de toutes les données
- (b) Dépend des données observées uniquement
- (c) Dépend des données manquantes uniquement
- (d) Dépend des données observées et manquantes

Réponse : b

2. Sous un mécanisme MCAR :

- (a) L'analyse sur les cas complets est biaisée
- (b) Les individus complets sont un sous-échantillon représentatif
- (c) Il faut obligatoirement imputer les données
- (d) La variance des estimateurs est plus faible

Réponse : b

3. L'hypothèse MAR est :

- (a) Testable par un test statistique
- (b) Non testable
- (c) Toujours vérifiée en pratique
- (d) Plus restrictive que MCAR

Réponse : b

4. Dans MICE, que signifie l'acronyme ?

- (a) Multiple Imputation by Chained Equations
- (b) Missing Information Criterion Estimate
- (c) Multivariate Imputation for Complete Estimation
- (d) Model-based Imputation for Censored Events

Réponse : a

5. Quelle est la conséquence de l'imputation simple sur les intervalles de confiance ?

- (a) Ils sont trop larges
- (b) Ils sont trop courts (sous-couverture)
- (c) Ils ne sont pas affectés

(d) Ils deviennent exacts

Réponse : b

6. Dans les règles de Rubin, la variance totale T est :

(a) $T = \bar{U}$ (variance intra uniquement)

(b) $T = B$ (variance inter uniquement)

(c) $T = \bar{U} + (1 + 1/M)B$

(d) $T = \bar{U} - (1 + 1/M)B$

Réponse : c

7. Quel package R propose l'imputation multiple par modèle gaussien joint ?

(a) `mice`

(b) `Amelia`

(c) `VIM`

(d) `missMDA`

Réponse : b

8. L'approche par analyse factorielle pour l'imputation (package `missMDA`) est particulièrement adaptée :

(a) Aux petites données

item À la grande dimension et la multicollinéarité

(b) Aux données qualitatives uniquement

(c) Aux séries temporelles

Réponse : b

9. La technique d'*overimputation* consiste à :

(a) Imputer plus de variables que nécessaire

(b) Générer des valeurs plausibles pour les données observées

(c) Supprimer les valeurs imputées

(d) Augmenter le nombre M d'imputations

Réponse : b

10. Quelle est la différence entre imputation et algorithme EM ?

(a) Aucune, ce sont les mêmes méthodes

(b) En imputation, le modèle d'imputation peut différer du modèle d'analyse

(c) L'EM ne nécessite pas de modèle

(d) L'imputation ne fonctionne que sous MCAR

Réponse : b

Références

- [1] R.J.A. Little, D.B. Rubin. *Statistical Analysis with Missing Data*. 2nd ed., Wiley, 2002.
- [2] S. van Buuren. *Flexible Imputation of Missing Data*. CRC Press, 2012.
- [3] V. Audigier, N. Niang. STA211 : gestion des données manquantes. Cours CNAM, 2026.
- [4] J.L. Schafer. Multiple imputation in multivariate problems when the imputation and analysis models differ. *Statistica Neerlandica*, 57(1):19–35, 2003.
- [5] J. Josse, F. Husson. `missMDA` : a package for handling missing values in multivariate data analysis. *Journal of Statistical Software*, 70(1):1–31, 2016.