

Fiche récapitulative – STA211

Étude de cas : pré-traitement des données German Credit

10 juin 2026

Résumé

Cette fiche présente un cas pratique complet de pré-traitement sur les données *German Credit* (UCI). Elle illustre le pipeline exploratoire et les transformations à appliquer avant la modélisation : importation, analyse univariée et bivariée, transformations de variables, réduction des données.

Table des matières

1	Introduction	2
1.1	Chargement et librairies	2
1.2	Nettoyage des noms	2
2	Aperçu général	2
3	Analyse univariée	2
3.1	Variables quantitatives	2
3.2	Graphiques	3
3.3	Boîtes à moustaches	3
3.4	Variables qualitatives	3
4	Analyse bivariée	3
4.1	Liens avec la variable réponse	3
4.2	Liens entre variables explicatives	4
5	Analyse multivariée	4
5.1	Analyse factorielle	4
5.2	Classification	5
5.3	Description des partitions	5
6	Transformations	5
6.1	Variables quantitatives	5
6.2	Variables qualitatives	5
6.3	Standardisation	5
7	Réduction des données	6
7.1	Réduction en lignes	6
7.2	Réduction en colonnes	6
8	Résumé du pipeline	6
	Questions clés (QCM)	7

Introduction

L'étude de cas applique les méthodes de pré-traitement vues en cours aux données **German Credit** (1 000 crédits, 21 variables, 20 explicatives + réponse binaire good/bad). L'objectif est de préparer les données pour une classification supervisée (prédire le statut bon ou mauvais payeur).

Données : [https://archive.ics.uci.edu/ml/datasets/statlog+\(german+credit\)](https://archive.ics.uci.edu/ml/datasets/statlog+(german+credit))

Chargement et librairies

```
1 library(stargazer)
2 library(FactoMineR)
3 library(DescTools)
4 library(car)
5 library(lattice)
6 library(gridExtra)
7
8 don <- read.table(
9   "https://archive.ics.uci.edu/ml/machine-learning-databases
10   /statlog/german/german.data",
11   sep = " ", stringsAsFactors = TRUE)
```

Nettoyage des noms

Les noms des variables et modalités sont codés (V1, V2, ..., A11, A12, ...). On les renomme d'après le descriptif UCI :

```
1 colnames(don) <- c("Status", "Duration", "History", "Purpose",
2   "Credit.Amount", "Savings account/bonds",
3   "Length.of.current.employment", "Instalment.per.cent",
4   "Sex.Marital.Status", "Guarantors",
5   "Duration.in.Current.address", "Property", "Age.years",
6   "Other.installment.plans", "Housing",
7   "No.of.Credits.at.this.Bank", "Job", "No.of.dependents",
8   "Telephone", "Foreign.Worker", "Creditability")
```

On modifie également le type des variables : Duration, Credit.Amount, Age.years en numeric, et Creditability en factor avec niveaux good/bad.

Aperçu général

```
1 dim(don)           # 1000 x 21
2 table(sapply(don, class))
3 # factor:14, integer:4, numeric:3
4 sum(is.na(don))     # 0 (aucune donnée manquante)
```

À retenir. Le jeu de données German Credit est complet (0 valeur manquante). Les étapes de pré-traitement se concentrent donc sur les transformations et la réduction, pas sur l'imputation.

Analyse univariée

Variabes quantitatives

Indicateurs statistiques : on utilise **stargazer** pour un tableau récapitulatif (min, Q1, médiane, moyenne, Q3, max, écart-type).

```

1 stargazer(don, summary.stat = c("n", "min", "p25", "median",
2                               "mean", "p75", "max", "sd"),
3           type = "text")

```

Constats :

- `Duration` (4–72 mois, médiane 18) : asymétrie droite.
- `Credit.Amount` (250–18 424, médiane 2 319) : forte asymétrie droite.
- `Age.years` (19–75, médiane 33) : asymétrie droite modérée.
- `Instalment.per.cent`, `Duration.in.Current.address`, `No.of.Credits.at.this.Bank`, `No.of.dependents` : variables discrètes à peu de modalités.

Graphiques

```

1 # Diagrammes en barres (variables discrètes)
2 varbarplot <- c("Instalment.per.cent",
3               "Duration.in.Current.address",
4               "No.of.Credits.at.this.Bank", "No.of.dependents")
5 mapply(don[,varbarplot], FUN = function(xx,name)
6        {barplot(table(xx), main = name)}, name = varbarplot)
7
8 # Histogrammes (variables continues)
9 varhist <- c("Duration", "Credit.Amount", "Age.years")
10 mapply(don[,varhist], FUN = function(xx,name)
11        {hist(xx, main = name)}, name = varhist)

```

Les histogrammes confirment l’asymétrie droite de `Duration`, `Credit.Amount` et `Age.years`. Une transformation logarithmique ou Box-Cox pourra être envisagée.

Boîtes à moustaches

```

1 library(car)
2 mapply(don[,varhist], FUN = function(xx,name)
3        {Boxplot(xx, main = name, id.n = 2)}, name = varhist)

```

Des valeurs apparaissent comme potentiellement aberrantes (notamment pour `Credit.Amount`), mais la décision de les traiter pourra être prise a posteriori si nécessaire.

Variables qualitatives

On détecte les modalités rares via des diagrammes en barres :

```

1 var.factor <- which(sapply(don, class) == "factor")
2 mapply(don[,var.factor], FUN = function(xx,name)
3        {barplot(table(xx), main = name, horiz = TRUE, las = 2,
4                  xlim = c(0,1000))},
5        name = names(var.factor))

```

Exemples de modalités rares : `noCredit.allPaid` et `thisBank.AllPaid` pour `History`, `Guarantor` pour `Guarantors`, etc. Ces modalités pourront être regroupées.

Analyse bivariée

Liens avec la variable réponse

Linéarité (variables quantitatives) : on représente la proportion de bons payeurs en fonction de chaque variable.

```

1 cont.table <- table(don$Duration, don$Creditability)
2 prof.lignes <- prop.table(cont.table, 1)
3 plot(as.numeric(rownames(prof.lignes)), prof.lignes[,1],
4      pch = 16, xlab = "Duree du credit",
5      ylab = "Proportion de bons payeurs")

```

La proportion de bons payeurs décroît linéairement avec la durée du crédit. Pour l'âge, la relation est non-monotone : une discrétisation en 3 classes est recommandée.

Rapports de corrélation η^2 :

```

1 library(BioStatR)
2 res.eta2 <- sapply(don[,var.numeric], eta2, y = don$Creditability)
3 barplot(sort(res.eta2), horiz = TRUE, las = 2, xlab = expression(eta^2))

```

Les variables les plus discriminantes : Duration et Credit.Amount. Les moins discriminantes : No.of.dependents et Duration.in.Current.address.

V de Cramer (variables qualitatives) :

```

1 library(DescTools)
2 res.cramer <- sapply(don[,var.factor[-which(names(var.factor)
3 == "Creditability")]],
4 FUN = function(xx) CramerV(table(xx, don$Creditability)))
5 barplot(sort(res.cramer), horiz = TRUE, las = 2, xlab = "V de Cramer")

```

Les plus liées : Status et History. Les moins liées : Job et Telephone.

À retenir. Les variables les moins discriminantes sont candidates à la suppression en cas de réduction de dimension.

Liens entre variables explicatives

Corrélations (quantitatives) :

```

1 matcor <- cor(don[, var.numeric])
2 PlotCorr(matcor) # visualisation
3 matcor.spearman <- cor(don[, var.numeric], method = "spearman")

```

On compare Pearson et Spearman : si $|r| \approx |\rho|$, la relation est linéaire ; si $|\rho| > |r|$, elle est monotone non linéaire.

Variables qualitatives : on utilise le V de Cramer ou le χ^2 pour détecter les liaisons fortes entre variables explicatives, qui pourraient causer de l'instabilité dans les modèles.

Analyse multivariée

Analyse factorielle

ACM (pour variables qualitatives) ou **AFDM** (mixtes) permettent de visualiser les proximités entre individus et modalités.

```

1 library(FactoMineR)
2 res.famd <- FAMD(don[, -ncol(don)], graph = FALSE)
3 plot(res.famd, choix = "var")
4 plot(res.famd, choix = "ind")

```

L'AFDM permet également de détecter des individus atypiques (contribution élevée à une dimension) et des liaisons entre variables qualitatives et quantitatives.

Classification

```
1 # CAH sur les composantes de l'AFDM
2 res.hcpc <- HCPC(res.famd, nb.clust = -1, graph = FALSE)
3 plot(res.hcpc)
```

La classification permet d'identifier des profils types de clients (segments homogènes) et de visualiser les caractéristiques de chaque cluster via la fonction `catdes`.

Description des partitions

```
1 catdes(don, num.var = ncol(don))
```

La fonction `catdes` décrit chaque modalité de la variable réponse (`good/bad`) à partir :

- Des variables quantitatives (test de Student, moyenne dans chaque groupe).
- Des modalités des variables qualitatives (test du χ^2 , proportion dans chaque groupe).

Transformations

Variables quantitatives

Discrétisation : on coupe l'âge en 3 classes pour gérer la non-linéarité observée :

```
1 Age.cut <- cut(don$Age.years,
2   breaks = quantile(don$Age.years, probs = c(0, 1/3, 2/3, 1)),
3   include.lowest = TRUE)
4 table(Age.cut)
```

Box-Cox : pour linéariser et symétriser les distributions.

```
1 library(MASS)
2 boxcox(lm(Credit.Amount ~ 1, data = don))
```

La transformation logarithmique ($\lambda \approx 0$) est souvent appropriée pour `Credit.Amount` et `Duration`.

Variables qualitatives

Regroupement de modalités : on fusionne les modalités rares qui ont un comportement similaire vis-à-vis de la réponse.

Exemple : `noCredit.allPaid` et `thisBank.AllPaid` de `History` ont des proportions de bons payeurs proches :

```
1 tmp <- table(don$History, don$Creditability)
2 prop.table(tmp, 1) # comparer les profils
3 levels(don$History)[1:2] <- "AllPaid"
```

Standardisation

Pour les méthodes sensibles aux échelles (ACP, régression, k -NN), on centre-réduit les variables quantitatives :

```
1 don.scaled <- as.data.frame(scale(don[, var.numeric]))
```

Réduction des données

Réduction en lignes

On peut supprimer les individus atypiques identifiés par :

- Distance de Mahalanobis robuste (MCD).
- Isolation Forest (peu sensible à la dimension).

```
1 library(robustbase)
2 mcd <- covMcd(don[, var.numeric])
3 dist <- mahalanobis(don[, var.numeric],
4                   center = mcd$center, cov = mcd$cov)
5 seuil <- qchisq(0.999, df = length(var.numeric))
6 outliers <- which(dist > seuil)
```

Réduction en colonnes

Sélection de variables :

- Éliminer les variables non discriminantes (faible η^2 , faible V de Cramer).
- Éliminer les variables redondantes (forte corrélation entre elles).
- Utiliser le Lasso pour une sélection automatique :

```
1 library(glmnet)
2 X <- model.matrix(Creditability ~ ., data = don)[, -1]
3 y <- don$Creditability
4 cv.lasso <- cv.glmnet(X, y, alpha = 1, family = "binomial")
5 coef(cv.lasso, s = "lambda.1se")
```

Extraction de caractéristiques :

- ACP (variables numériques), ACM (qualitatives), AFDM (mixtes).
- On conserve les premières composantes qui résument l'essentiel de l'information.

```
1 res.pca <- PCA(don[, var.numeric], scale.unit = TRUE, graph = FALSE)
2 barplot(res.pca$eig[, 2], main = "Variance expliquée")
3 # Souvent 2-3 composantes suffisent
```

Résumé du pipeline

1. **Import** : charger, renommer, typer.
2. **Aperçu** : dimensions, types, valeurs manquantes.
3. **Analyse univariée** : distributions, atypiques, modalités rares.
4. **Analyse bivariée** : lien avec Y (linéarité, η^2 , V de Cramer), lien entre X .
5. **Analyse multivariée** : AFDM, CAH, catdes.
6. **Transformations** : Box-Cox, discrétisation, regroupement, standardisation.
7. **Réduction** : suppression d'atypiques, sélection de variables (Lasso), extraction (ACP/AFDM).
8. **Modélisation** : appliquer la méthode choisie sur les données prétraitées.

Questions clés (QCM)

1. Dans l'étude de cas German Credit, combien de variables le jeu de données contient-il ?
- (a) 1000
 - (b) 21
 - (c) 20
 - (d) 14

Réponse : b (21 variables dont 20 explicatives + réponse).

2. Le jeu de données German Credit contient-il des valeurs manquantes ?
- (a) Oui, beaucoup
 - (b) Non, il est complet
 - (c) Oui, 5%
 - (d) On ne peut pas savoir

Réponse : b (`sum(is.na(don)) = 0`).

3. Quelle variable quantitative est la plus discriminante (liée à la réponse) selon le η^2 ?
- (a) Age.years
 - (b) Duration
 - (c) Instalment.per.cent
 - (d) No.of.dependents

Réponse : b (Duration).

4. Quelle variable qualitative est la plus discriminante selon le V de Cramer ?
- (a) Telephone
 - (b) Job
 - (c) Status
 - (d) Housing

Réponse : c (Status).

5. La relation entre Age et la proportion de bons payeurs est :
- (a) Linéaire croissante
 - (b) Linéaire décroissante
 - (c) Non monotone
 - (d) Il n'y a pas de relation

Réponse : c (non monotone, d'où la discrétisation en 3 classes).

6. Quel package R permet de calculer le η^2 ?
- (a) stargazer
 - (b) DescTools
 - (c) BioStatR
 - (d) FactoMineR

Réponse : c (BioStatR, fonction `eta2`).

7. La fonction `catdes` du package FactoMineR permet de :
- (a) Visualiser les corrélations
 - (b) Décrire une partition par les variables
 - (c) Effectuer une ACP
 - (d) Imputer les valeurs manquantes

Réponse : b (description d'une partition).

8. Pour gérer la non-linéarité de l'âge, on recommande :

- (a) Une transformation logarithmique
- (b) Une discrétisation en 3 classes
- (c) Une standardisation
- (d) La suppression de la variable

Réponse : b (discrétisation en 3 classes par quantiles).

9. Le Lasso (régression pénalisée L1) permet :

- (a) D'imputer les données manquantes
- (b) De sélectionner automatiquement les variables
- (c) De visualiser les clusters
- (d) De transformer les variables

Réponse : b (sélection de variables via pénalité L1).

10. Quel est l'ordre recommandé du pipeline de pré-traitement ?

- (a) Modélisation → transformation → analyse
- (b) Analyse → transformation → réduction → modélisation
- (c) Réduction → modélisation → analyse
- (d) Transformation → modélisation → analyse

Réponse : b (analyse exploratoire → transformations → réduction → modélisation).

Références

- [1] UCI Machine Learning Repository. *German Credit Data*. [https://archive.ics.uci.edu/ml/datasets/statlog+\(german+credit\)](https://archive.ics.uci.edu/ml/datasets/statlog+(german+credit))
- [2] V. Audigier, N. Niang. STA211 : pré-traitement, étude de cas. Cours CNAM, 2026.
- [3] S. Tufféry. *Data Mining et statistique décisionnelle*. Technip, 2007.
- [4] M. Lejeune. *Statistique : la théorie et ses applications*. Springer, 2010.
- [5] L. Lebart, A. Morineau, M. Piron. *Statistique exploratoire multidimensionnelle*. Dunod, 2006.