

Fiche récapitulative – STA211

Détection des points atypiques via *Isolation Forest*

10 juin 2026

Résumé

Cette fiche présente la méthode *Isolation Forest* pour la détection non supervisée des valeurs atypiques. Elle couvre le principe (isolement rapide des anomalies par des arbres aléatoires), la construction des arbres, le calcul du score d'anomalie, le paramétrage, et une application sur les données German Credit avec le package R `isotree`.

Table des matières

1	Contexte	2
2	Principe	2
3	Construction des arbres au hasard	2
3.1	Algorithme de construction d'un arbre	2
3.2	Sous-échantillonnage et effet de masque	2
3.3	Forêt	2
4	Calcul du score	3
4.1	Profondeur d'isolement	3
4.2	Normalisation par $c(n)$	3
4.3	Score d'anomalie	3
5	Paramétrage	3
5.1	Nombre d'arbres (B)	3
5.2	Taille du sous-échantillon	3
5.3	Seuillage des scores	4
6	Application aux données German Credit	4
6.1	Chargement et importation	4
6.2	Construction du modèle	4
6.3	Stabilisation des scores	4
6.4	Seuillage et identification	4
6.5	Post-analyse	5
7	Conclusion	5
	Questions clés (QCM)	5

Contexte

La détection des points atypiques (ou *outliers*) est une étape importante en fouille de données. Du point de vue géométrique, il s'agit de points qui s'écartent significativement des autres : ils sont peu nombreux et localisés dans une zone peu dense du nuage de points. Leur détection est un enjeu car les analyses effectuées sur des échantillons contenant ces points peuvent conduire à des résultats très différents.

Isolation Forest ([1]) est une méthode de référence qui s'appuie sur les forêts aléatoires dans un cadre non supervisé.

Principe

La détection se fait ici d'un point de vue complètement **non supervisé**. Les forêts étant des méthodes supervisées, la construction des arbres y est différente.

Le principe d'*Isolation Forest* :

1. Construire des arbres **au hasard** qui vont fournir différents découpages de l'espace.
2. Le postulat : les valeurs atypiques vont rapidement être isolées dans une région (peu de coupures nécessaires), contrairement aux observations normales qui seront isolées à un niveau plus profond de l'arbre.
3. On regarde à quelle profondeur de l'arbre une observation est isolée en moyenne. Ceci fournit un score par observation.
4. Les scores sont ensuite seuillés pour déterminer les valeurs atypiques.

À retenir. L'idée centrale : plus une observation est isolée rapidement (faible profondeur), plus elle est susceptible d'être atypique.

Construction des arbres au hasard

Algorithme de construction d'un arbre

1. Sélectionner au hasard une variable parmi les p variables.
2. Choisir au hasard un point de coupure dans l'étendue de cette variable.
3. Segmenter l'échantillon en deux sous-groupes.
4. Répéter itérativement jusqu'à ce qu'un nœud :
 - (a) ne contienne qu'un seul individu, ou
 - (b) atteigne une profondeur prédéfinie.

Sous-échantillonnage et effet de masque

Pour construire une forêt, la procédure commence par un **sous-échantillonnage** afin de limiter l'**effet de masque** (*masking effect*). Ce phénomène correspond au fait que la procédure de détection doit elle-même faire face aux valeurs atypiques. Les valeurs atypiques peuvent avoir un impact sur la méthode de détection et ainsi masquer certaines d'entre elles.

En tirant un sous-échantillon, les points atypiques seront plus rapidement isolés et donc mieux détectés.

Forêt

Une fois le sous-échantillonnage effectué, on construit un premier arbre au hasard, puis on recommence B fois pour obtenir une forêt de B arbres.

Calcul du score

Profondeur d'isolement

Étant donnée une observation x , on note $h(x)$ la profondeur de x dans un arbre (nombre d'arêtes entre la racine et le nœud terminal contenant x).

Sur la base d'une forêt de B arbres, on note $\bar{h}(x) = \frac{1}{B} \sum_{b=1}^B h_b(x)$ la profondeur moyenne de x dans la forêt.

Normalisation par $c(n)$

Comme la profondeur d'un arbre dépend du nombre d'observations, on relativise $\bar{h}(x)$ par la profondeur moyenne attendue pour un arbre de n observations :

$$c(n) = 2 \times H(n-1) - \frac{2(n-1)}{n} \quad (1)$$

où $H(k) = \sum_{i=1}^k \frac{1}{i}$ est le k -ième nombre harmonique. $c(n)$ est la profondeur moyenne d'un arbre construit au hasard sur n observations.

Score d'anomalie

On définit le score de l'observation x :

$$s(x, n) = 2^{-\frac{\bar{h}(x)}{c(n)}} \quad (2)$$

Interprétation :

- $s(x, n) \approx 0.5$: l'observation est normale ($\bar{h}(x) \approx c(n)$).
- $s(x, n) \rightarrow 1$: l'observation est très probablement atypique ($\bar{h}(x) \ll c(n)$, isolement rapide).
- $s(x, n) \rightarrow 0$: l'observation est plutôt normale ($\bar{h}(x) \gg c(n)$, isolement profond).

À retenir. Le score $s(x, n)$ est une standardisation de $\bar{h}(x)$ comprise entre 0 et 1. Plus le score est proche de 1, plus l'observation est atypique.

Paramétrage

La méthode dépend de trois paramètres principaux :

Nombre d'arbres (B)

Le nombre d'arbres a une incidence sur la variance des profondeurs moyennes $\bar{h}(x)$. Plus B est grand, plus l'estimation est stable. En pratique, $B = 100$ est souvent suffisant, $B = 300$ donne une très bonne stabilité.

Taille du sous-échantillon

[1] indiquent que tirer un sous-échantillon de **256 observations** est suffisant et qu'il n'y a pas de gain substantiel à choisir un nombre plus élevé. Cela permet de réduire le coût computationnel.

Remarque. Ce nombre de 256 est souvent repris dans la littérature mais sa portée reste limitée (basé sur une étude par simulation).

Seuillage des scores

Une fois le score calculé pour chaque observation, il convient de le seuiller pour déterminer les observations atypiques. Il n'y a pas de valeur seuil universelle.

Méthode pratique : observer la distribution des scores et chercher un décrochage (*elbow*) dans la distribution. Les points au-delà du coude sont considérés comme atypiques.

Application aux données German Credit

On utilise le package `isotree` ([2]) sur les données German Credit ($n = 1000$, $p = 21$, pas de valeurs manquantes).

Chargement et importation

```
1 library(isotree)
2 library(FactoMineR)
3
4 don <- read.table(
5   "https://archive.ics.uci.edu/ml/machine-learning-databases
6   /statlog/german/german.data",
7   sep = " ", stringsAsFactors = TRUE)
```

Construction du modèle

On applique *Isolation Forest* avec $B = 300$ arbres et un sous-échantillon de taille 256 :

```
1 set.seed(1234)
2 ntree <- 300
3 sample_size <- 256
4
5 model <- isolation_forest(don,
6   sample_size = sample_size,
7   ntrees = ntree)
```

Stabilisation des scores

On étudie la stabilisation des scores en fonction du nombre d'arbres :

```
1 subscores <- sapply(seq.int(ntree),
2   FUN = function(nbtrees, model, don) {
3     submodel <- isotree_subset_trees(model,
4     trees_take = seq.int(nbtrees))
5     predict_isolation_forest(submodel, newdata = don)
6   }, model = model, don = don)
7
8 matplot(t(subscores), type = "b", pch = 14, cex = .1,
9   ylab = "score", xlab = "nombre d'arbres")
```

Les scores se stabilisent à partir de 100 arbres.

Seuillage et identification

```
1 scores <- predict_isolation_forest(model, newdata = don)
2 scores <- sort(scores, decreasing = TRUE)
3
4 plot(scores, type = "b", pch = 16, cex = 0.2,
5   xlab = "rang")
```

```

6 threshold <- 0.576
7 abline(h = threshold, col = "red", lty = 2)
8
9 which(scores > threshold)
10 # 375 757 916 187 851 227 928 890 614

```

Neuf observations sont identifiées comme atypiques avec un seuil de 0.576.

Post-analyse

L'*Isolation Forest* fournit un score par observation sur la base de l'ensemble des variables, mais n'indique pas quelles variables expliquent ce caractère atypique. On peut utiliser une analyse factorielle (AFDM) pour analyser les caractéristiques des individus atypiques :

```

1 res.FAMD <- FAMD(don,
2   ind.sup = as.numeric(names(which(scores > threshold))),
3   sup.var = which(colnames(don) == "Creditability"),
4   graph = FALSE)
5 plot(res.FAMD, choix = "ind", cex = .5)

```

Il s'agit ensuite d'identifier les variables contribuant à la construction des axes sur lesquels ces observations ont des coordonnées élevées.

Conclusion

Isolation Forest est une méthode de référence pour la détection des valeurs atypiques :

- Faible coût algorithmique (complexité linéaire), permettant de traiter des échantillons de grande taille.
- Non sensible aux problèmes d'échelle (pas de standardisation nécessaire).
- Extension aux données mixtes directe.

Une fois les points atypiques identifiés, on peut :

- Utiliser des méthodes d'analyse *robustes*.
- Remplacer les valeurs jugées atypiques par des valeurs manquantes puis effectuer une imputation.

Le package **isotree** ([2]) propose différentes extensions, notamment la segmentation selon des combinaisons de variables.

Questions clés (QCM)

1. Quel est le principe de base d'*Isolation Forest* ?
 - (a) Les points atypiques sont isolés rapidement par les arbres
 - (b) Les points atypiques sont identifiés par leur distance au centre
 - (c) Les points atypiques sont détectés par des méthodes supervisées
 - (d) Les points atypiques sont toujours en profondeur maximale

Réponse : a (isolement rapide des anomalies).

2. Dans la construction d'un arbre, comment sont choisis la variable et le point de coupure ?
 - (a) Par optimisation d'un critère (Gini, entropie)
 - (b) Au hasard
 - (c) Par validation croisée
 - (d) Par recherche exhaustive

Réponse : b (variable et point de coupure choisis au hasard).

3. Quelle est la formule du score d'anomalie $s(x, n)$?

- (a) $s(x, n) = 2^{-\bar{h}(x)/c(n)}$
- (b) $s(x, n) = \bar{h}(x)/c(n)$
- (c) $s(x, n) = 2^{\bar{h}(x)/c(n)}$
- (d) $s(x, n) = -\bar{h}(x)/c(n)$

Réponse : a ($s(x, n) = 2^{-\bar{h}(x)/c(n)}$).

4. Que représente $c(n)$ dans le calcul du score ?

- (a) La profondeur maximale de l'arbre
- (b) La profondeur moyenne attendue pour un arbre aléatoire sur n observations
- (c) Le nombre d'arbres dans la forêt
- (d) La variance des scores

Réponse : b (profondeur moyenne attendue).

5. Un score $s(x, n) \approx 0.5$ indique :

- (a) Une observation très atypique
- (b) Une observation normale
- (c) Une observation anormale
- (d) Une erreur de calcul

Réponse : b ($\bar{h}(x) \approx c(n)$, observation normale).

6. Quelle est la taille de sous-échantillon recommandée par Liu, Ting & Zhou (2008) ?

- (a) 128
- (b) 256
- (c) 512
- (d) 1000

Réponse : b (256 observations).

7. Quel est l'intérêt du sous-échantillonnage dans *Isolation Forest* ?

- (a) Réduire la variance du modèle
- (b) Limiter l'effet de masque
- (c) Accélérer l'entraînement seulement
- (d) Éviter le sur-apprentissage

Réponse : b (limiter l'effet de masque).

8. Quel package R implémente *Isolation Forest* ?

- (a) randomForest
- (b) isotree
- (c) rpart
- (d) xgboost

Réponse : b (isotree).

9. *Isolation Forest* nécessite-t-elle une standardisation préalable des données ?

- (a) Oui, toujours
- (b) Non, elle n'est pas sensible aux échelles
- (c) Oui, si les variables sont de natures différentes
- (d) Cela dépend du jeu de données

Réponse : b (non sensible aux échelles, pas de standardisation nécessaire).

10. Dans l'application German Credit, combien d'observations sont identifiées comme atypiques avec le seuil de 0.576 ?

- (a) 3
- (b) 6
- (c) 9
- (d) 12

Réponse : c (9 observations atypiques).

Références

- [1] F. T. Liu, K. M. Ting, Z.-H. Zhou. *Isolation Forest*. ICDM, pp. 413–422, IEEE, 2008.
- [2] D. Cortes. *isotree: Isolation-Based Outlier Detection*. <https://doi.org/10.32614/CRAN.package.isotree>, 2026.
- [3] V. Audigier. STA211 : détection des points atypiques via *Isolation Forest*. Cours CNAM, 2026.
- [4] R. Rakotomalala. Détection des anomalies : *Isolation Forest*. https://eric.univ-lyon2.fr/ricco/cours/slides/isolation_forest.pdf