

Fiche récapitulative – STA211

Exploitation des méthodes exploratoires
pour le pré-traitement des données

10 juin 2026

Résumé

Cette fiche synthétise le cours d'Exploitation des méthodes exploratoires pour le pré-traitement des données (V. Audigier, N. Niang). Le pré-traitement transforme les données brutes en un format adapté à l'analyse. Les méthodes exploratoires aident à comprendre la structure des données avant d'appliquer des modèles prédictifs.

Table des matières

1	Présentation	2
2	Transformation des variables quantitatives	2
2.1	Discrétisation	2
2.2	Linéarité	2
2.3	Normalité	3
3	Transformation des variables qualitatives	3
3.1	Regroupement de modalités	3
3.2	Analyse factorielle	4
4	Détection des points atypiques	4
4.1	Méthodes univariées	4
4.2	Méthodes multivariées	4
5	Gestion des données manquantes	5
5.1	Mécanismes de manquant	5
5.2	Approches par suppression	5
5.3	Imputation simple	5
5.4	Imputation multiple – MICE	5
6	Réduction de dimension	6
6.1	Sélection <i>vs</i> extraction	6
6.2	Méthodes d'extraction	6
6.3	Méthodes de sélection	6
6.4	Clustering de variables	6
7	Pré-traitement des données volumineuses	6
8	Code Python – Exemples	7
9	Code R – Exemples	8
	Questions clés (QCM)	9

Présentation

Le pré-traitement est une étape cruciale de tout processus d'analyse de données. Les données brutes contiennent souvent des imperfections : valeurs aberrantes, données manquantes, échelles hétérogènes, variables redondantes, etc. Ignorer ces problèmes conduit à des résultats biaisés ou peu robustes.

Les méthodes exploratoires jouent un double rôle :

1. **Diagnostic** : mettre en évidence les caractéristiques des données (distributions, corrélations, atypiques, manquantes).
2. **Transformation** : corriger ou adapter les données pour les rendre compatibles avec les méthodes d'analyse ultérieures.

Questions clés abordées dans ce cours :

- Comment transformer les variables (quantitatives et qualitatives) ?
- Comment détecter et traiter les points atypiques ?
- Comment gérer les données manquantes ?
- Comment réduire la dimension des données ?
- Comment traiter les données volumineuses ?

Transformation des variables quantitatives

Discrétisation

La discrétisation transforme une variable continue en classes discrètes. Utile pour : applicabilité de certains algorithmes, interprétabilité, robustesse au bruit.

Règles métier

Découpage selon des seuils ayant un sens métier. Exemple : âge en classes : $[0, 18[$, $[18, 25[$, $[25, 45[$, $[45, 65[$, $65+$. Simple, pertinent mais subjectif.

Quantiles

Classes d'effectifs égaux (déciles, quartiles). Exemple : âge en 3 quantiles : $[18, 32[$, $[32, 51[$, $[51, 95]$. Objectif mais peut créer des frontières artificielles.

CAH / k -means

On regroupe les valeurs par clustering univarié puis on utilise les clusters comme catégories. S'adapte à la structure naturelle des données.

MDLPC

Minimum Description Length Principle Cut : discrétisation supervisée qui minimise la perte d'information vis-à-vis d'une cible Y . Choisit les coupures qui maximisent le gain d'information.

À retenir. La discrétisation fait perdre de l'information (perte de granularité). À utiliser avec parcimonie, et valider l'impact sur l'analyse aval.

Linéarité

De nombreux modèles (régression linéaire, ACP) supposent des relations linéaires entre variables. Une transformation peut linéariser la relation.

Détection :

- Coefficient de Pearson r : mesure la corrélation linéaire.
- Coefficient de Spearman ρ : mesure la corrélation de rang (monotone, pas forcément linéaire).
- Si $|r| \approx |\rho|$: relation approximativement linéaire.
- Si $|\rho| > |r|$: relation monotone mais non linéaire $\rightarrow$ besoin de transformation.

Transformation de Box-Cox :

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0, \\ \log(y) & \text{si } \lambda = 0. \end{cases}$$

Le paramètre λ est estimé par maximum de vraisemblance (ou *profile likelihood*). On cherche λ tel que $y^{(\lambda)}$ soit le plus linéaire possible par rapport aux autres variables.

Normalité

De nombreux tests et modèles supposent la normalité des résidus ou des variables.

Indicateurs de non-normalité :

— Asymétrie (*skewness*) :

$$\gamma_1 = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right].$$

$\gamma_1 = 0$ pour une normale. $\gamma_1 > 0$: queue à droite. $\gamma_1 < 0$: queue à gauche.

— Aplatissement (*kurtosis*) :

$$\gamma_2 = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] - 3.$$

$\gamma_2 = 0$ pour une normale. $\gamma_2 > 0$: distribution leptokurtique (pointue). $\gamma_2 < 0$: platykurtique (aplatie).

— Test de Shapiro-Wilk, test de Jarque-Bera.

— QQ-plot : quantiles empiriques vs quantiles théoriques. L'alignement des points sur la diagonale indique la normalité.

Transformations correctives :

— Logarithme : $\log(x)$ pour des données strictement positives avec asymétrie droite.

— Racine carrée : $\sqrt{x}$ pour des données de comptage.

— Box-Cox (cf. ci-dessus) : généralisation.

— Yeo-Johnson : analogue à Box-Cox mais accepte les valeurs négatives.

Transformation des variables qualitatives**Regroupement de modalités**

Les variables qualitatives comportent parfois un grand nombre de modalités, dont certaines très rares. Le regroupement vise à :

- Éviter les indicateurs binaires de faible effectif (instables).
- Améliorer la parcimonie et l'interprétabilité.

Méthodes :

1. Expertise métier : regroupement basé sur la connaissance du domaine.
2. Clustering des modalités : on représente chaque modalité par son profil (e.g. via ACM), puis on regroupe les modalités proches.
3. Fusion supervisée : pour une cible Y donnée, on regroupe les modalités dont la moyenne de Y est similaire (test de Student ou ANOVA).

Analyse factorielle

L'analyse factorielle (ACM, AFDM) permet de convertir des variables qualitatives en représentations numériques continues. Les coordonnées des individus sur les axes factoriels deviennent de nouvelles variables quantitatives.

- **ACM (MCA)** : pour données qualitatives uniquement. Transforme le tableau disjonctif complet en composantes continues.
- **AFDM (FAMD)** : pour données mixtes (quantitatives + qualitatives). Combine ACP (pour les quantitatives) et ACM (pour les qualitatives).

À retenir. L'analyse factorielle n'est pas seulement une méthode de visualisation : c'est aussi un outil de pré-traitement pour remplacer des variables brutes par des composantes synthétiques.

Détection des points atypiques

Méthodes univariées

Z-score :

$$z_i = \frac{x_i - \bar{x}}{s},$$

où $\bar{x}$ est la moyenne et s l'écart-type. On considère comme atypique une observation avec $|z_i| > 3$ (seuil de la normale à 99,7 %). Limite : la moyenne et l'écart-type sont sensibles aux valeurs extrêmes (effet de masquage).

Intervalle interquartile (IQR) :

$$\text{IQR} = Q_3 - Q_1.$$

Sont atypiques les valeurs $< Q_1 - 1,5 \times \text{IQR}$ ou $> Q_3 + 1,5 \times \text{IQR}$. Plus robuste que le Z-score car basé sur les quartiles.

Méthodes multivariées

Distance de Mahalanobis :

$$D_i^2 = (\mathbf{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}).$$

Sous hypothèse de normalité multivariée, $D_i^2 \sim \chi_p^2$ avec p le nombre de variables. On considère atypiques les individus dont la p -valeur associée est $< 0,001$ (ou autre seuil).

En pratique, $\boldsymbol{\mu}$ et $\boldsymbol{\Sigma}$ sont estimés sur l'échantillon, mais ces estimateurs sont sensibles aux atypiques. On utilise alors l'estimateur MCD (*Minimum Covariance Determinant*) qui minimise le déterminant de la matrice de covariance sur un sous-ensemble robuste.

Isolation Forest [1] :

- Algorithme non supervisé basé sur des arbres de décision aléatoires.
- Principe : on isole chaque observation en partitionnant aléatoirement l'espace des variables.
- Un point atypique est isolé en moins de coupes (chemin plus court dans l'arbre) qu'un point normal.

Score d'anomalie :

$$s(x, n) = 2^{-\frac{\mathbb{E}[h(x)]}{c(n)}}, \quad c(n) = 2H(n-1) - \frac{2(n-1)}{n},$$

où $h(x)$ est la longueur du chemin dans l'arbre, $c(n)$ un facteur de normalisation et $H(i)$ le i -ième nombre harmonique. $s \rightarrow 1$: atypique, $s \rightarrow 0$: normal.

Gestion des données manquantes

Mécanismes de manquant

MCAR

(*Missing Completely At Random*) : la probabilité de manquant ne dépend ni des données observées ni des données manquantes. Exemple : questionnaire perdu aléatoirement.

MAR

(*Missing At Random*) : la probabilité de manquant dépend des données observées mais pas des données manquantes. Exemple : les hommes répondent moins à une question sur le poids.

MNAR

(*Missing Not At Random*) : la probabilité de manquant dépend des données manquantes elles-mêmes. Exemple : les personnes à haut revenu ne déclarent pas leur revenu.

À retenir. Le mécanisme de manquant est une hypothèse non testable (car on n'observe pas les données manquantes). Il faut justifier son choix par des arguments métier.

Approches par suppression

- **Listwise deletion (analyse des cas complets)** : on supprime toute ligne comportant au moins une valeur manquante. Simple mais : (i) perte de puissance, (ii) biais sauf si MCAR.
- **Pairwise deletion** : on utilise toutes les observations disponibles pour chaque calcul (moyenne, corrélation). La matrice de covariance peut ne pas être définie positive.

Imputation simple

- **Moyenne / médiane** : remplace la valeur manquante par la moyenne (ou médiane) de la variable. Atténue la variance et les corrélations.
- **Imputation par régression** : on prédit la valeur manquante à partir des autres variables. Tendance à renforcer les relations existantes.
- **Hot-deck (k-NN)** : on trouve les k plus proches voisins complets et on impute par leur moyenne (ou un tirage aléatoire).

Imputation multiple – MICE

MICE (*Multiple Imputation by Chained Equations*) : méthode itérative qui génère m jeux de données imputés, en tenant compte de l'incertitude d'imputation.

Algorithme :

1. Imputation initiale provisoire (e.g. moyenne).
2. Pour chaque variable X_j contenant des valeurs manquantes :
 - (a) Régression de X_j sur toutes les autres variables (sur les observations où X_j est observée).
 - (b) Imputation des valeurs manquantes de X_j par tirage dans la distribution prédictive (valeur prédite + bruit).
3. Répéter l'étape 2 pendant plusieurs cycles (5–10) pour stabiliser les imputations.
4. Répéter tout le processus m fois (typiquement $m = 5$ ou $m = 20$) $\rightarrow m$ jeux de données complets.
5. Analyser chaque jeu séparément et combiner les résultats avec les règles de Rubin.

Règles de Rubin :

$$\bar{Q} = \frac{1}{m} \sum_{j=1}^m \hat{Q}_j, \quad B = \frac{1}{m-1} \sum_{j=1}^m (\hat{Q}_j - \bar{Q})^2, \quad T = \bar{U} + \left(1 + \frac{1}{m}\right) B.$$

où $\hat{Q}_j$ est l'estimation du paramètre d'intérêt sur le j -ème jeu imputé, U_j sa variance estimée, $\bar{U} = \frac{1}{m} \sum U_j$ la variance intra-imputation, B la variance inter-imputation, et T la variance totale.

Réduction de dimension

Sélection *vs* extraction

Deux stratégies complémentaires :

- **Sélection de variables** : choisir un sous-ensemble des variables originales. Avantage : interprétabilité préservée. Inconvénient : information redondante partiellement perdue.
- **Extraction de caractéristiques** : créer de nouvelles variables synthétiques (composantes, facteurs). Avantage : capte l'information de toutes les variables. Inconvénient : perte d'interprétabilité directe.

Méthodes d'extraction

ACP (PCA)

Trouve les directions de variance maximale dans l'espace des variables. Les composantes principales sont orthogonales. Adaptée aux variables numériques.

ACM (MCA)

Version de l'ACP pour variables qualitatives. Appliquée au tableau disjonctif complet.

AFDM (FAMD)

Mélange ACP + ACM pour données mixtes.

PLS (*Partial Least Squares*)

Trouve des composantes qui maximisent la covariance entre X et Y . Supervisée.

Méthodes de sélection

- **Best subset** : testing all 2^p subsets. Impossible pour p grand.
- **Sélection pas-à-pas** : forward (ajout), backward (retrait), stepwise (les deux).
- **Régularisation (Lasso, Ridge, Elastic Net)** :

$$\hat{\beta} = \arg \min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_q^q,$$

avec $q = 1$ (Lasso, fait de la sélection), $q = 2$ (Ridge, réduit sans sélectionner), ou un mélange (Elastic Net).

Clustering de variables

Objectif : identifier des groupes de variables corrélées pour détecter la redondance.

Démarche :

1. Calculer la matrice de corrélation $\mathbf{R}$.
2. Définir une distance entre variables, par exemple $d(X_j, X_k) = 1 - |r_{jk}|$.
3. Appliquer une CAH sur les variables (et non sur les individus).

Chaque cluster peut ensuite être résumé par une variable synthétique (la première composante de l'ACP intra-cluster).

Pré-traitement des données volumineuses

Avec des jeux de données massifs, les méthodes classiques deviennent coûteuses, voire impossibles à exécuter en mémoire.

Stratégies :

- **Échantillonnage** : réduire la taille des données.

- Aléatoire simple : tirage uniforme sans remise.
- Systématique : on sélectionne 1 individu tous les k .
- Stratifié : tirage par strates pour préserver la structure.
- **Sous-échantillonnage pour Isolation Forest** : chaque arbre est construit sur un petit sous-échantillon (e.g. 256 individus). Cela améliore la robustesse et réduit le coût.
- **Parallélisation** : diviser les données en blocs, traiter chaque bloc indépendamment, puis combiner les résultats.
- **Algorithmes en ligne (*streaming*)** : mise à jour incrémentale des paramètres (e.g. SGD, ACP incrémentale).

Code Python – Exemples

Listing 1 – Box-Cox et détection d'atypiques

```

1 import numpy as np
2 from scipy.stats import boxcox
3 from scipy.spatial.distance import mahalanobis
4
5 # --- Transformation Box-Cox ---
6 data = np.array([1, 2, 3, 5, 10, 20, 50])
7 transformed, lambda_opt = boxcox(data)
8 print(f"lambda optimal: {lambda_opt:.3f}")
9
10 # --- Distance de Mahalanobis robuste ---
11 from sklearn.covariance import MinCovDet
12 X = np.random.randn(100, 5)
13 mcd = MinCovDet().fit(X)
14 dist = mcd.mahalanobis(X)
15 seuil = np.sqrt(mcd.dof_) # approx chi2(p)
16 outliers = dist > seuil
17 print(f"Atteinte robuste Mahalanobis: {outliers.sum()} atypiques")

```

Listing 2 – Isolation Forest

```

1 from sklearn.ensemble import IsolationForest
2 rng = np.random.RandomState(42)
3 X = 0.3 * rng.randn(100, 2)
4 X_outliers = rng.uniform(low=-4, high=4, size=(20, 2))
5 X = np.vstack([X, X_outliers])
6
7 model = IsolationForest(contamination=0.1, random_state=rng)
8 y_pred = model.fit_predict(X)
9 # -1 = outlier, 1 = normal
10 print(f"Atteinte Isolation Forest: {(y_pred == -1).sum()} atypiques")

```

Listing 3 – Imputation multiple avec IterativeImputer

```

1 from sklearn.experimental import enable_iterative_imputer
2 from sklearn.impute import IterativeImputer
3 import pandas as pd
4
5 df = pd.DataFrame({
6     'X1': [1, 2, np.nan, 4, 5],
7     'X2': [5, np.nan, 3, 2, 1],
8     'X3': [1, 1, 0, 0, 1]
9 })
10 imp = IterativeImputer(max_iter=10, random_state=0)

```

```

11 df_imputed = pd.DataFrame(imp.fit_transform(df),
12                             columns=df.columns)
13 print(df_imputed)

```

Listing 4 – ACP et Lasso

```

1 from sklearn.decomposition import PCA
2 from sklearn.linear_model import LassoCV
3 from sklearn.preprocessing import StandardScaler
4
5 # ACP
6 scaler = StandardScaler()
7 X_scaled = scaler.fit_transform(X)
8 pca = PCA(n_components=2)
9 X_pca = pca.fit_transform(X_scaled)
10 print(f"Variance expliquée: {pca.explained_variance_ratio_}")
11
12 # Lasso
13 lasso = LassoCV(cv=5, random_state=0).fit(X_scaled, y)
14 print(f"Variables sélectionnées: {np.where(lasso.coef_ != 0)[0]}")

```

Code R – Exemples

Listing 5 – Box-Cox et Mahalanobis

```

1 library(MASS)
2 library(robustbase)
3
4 # --- Box-Cox ---
5 boxcox(lm(mpg ~ ., data = mtcars))
6
7 # --- Distance de Mahalanobis robuste ---
8 data(iris)
9 X <- iris[, 1:4]
10 mcd <- covMcd(X)
11 dist <- mahalanobis(X, center = mcd$center, cov = mcd$cov)
12 seuil <- qchisq(0.999, df = ncol(X))
13 outliers <- dist > seuil
14 cat("Atteinte Mahalanobis robuste:", sum(outliers), "atypiques\n")

```

Listing 6 – Isolation Forest avec isotree

```

1 library(isotree)
2 set.seed(42)
3 iso <- isolation.forest(X, ntrees = 100, sample_size = 256,
4                         ndim = ncol(X))
5 scores <- predict(iso, X)
6 cat("Score d'anomalie (moy.):", mean(scores), "\n")

```

Listing 7 – Imputation multiple avec mice

```

1 library(mice)
2 data(nhanes)
3 imp <- mice(nhanes, m = 5, method = 'pmm', seed = 123)
4 # Combinaison des resultats (regression)
5 fit <- with(imp, lm(bmi ~ age + chl))
6 pooled <- pool(fit)
7 summary(pooled)

```


Listing 8 – ACP, FAMD et Lasso

```
1 library(FactoMineR)
2 library(glmnet)
3
4 # ACP
5 res.pca <- PCA(iris[, 1:4], scale.unit = TRUE, graph = FALSE)
6 print(res.pca$eig[1:2, ])
7
8 # FAMD (donnees mixtes)
9 data(geomorphology)
10 res.famd <- FAMD(geomorphology, graph = FALSE)
11
12 # Lasso
13 X <- as.matrix(iris[, 1:4])
14 y <- iris[, 5]
15 cv.lasso <- cv.glmnet(X, as.numeric(y), alpha = 1, nfolds = 5)
16 coef(cv.lasso, s = "lambda.1se")
```

Questions clés (QCM)

Voici 10 questions pour vérifier votre compréhension. Les réponses sont fournies ci-dessous.

1. Quelle transformation est recommandée pour linéariser une relation monotone non linéaire ?
 - (a) Transformation logarithmique
 - (b) Transformation de Box-Cox
 - (c) Centrage-réduction
 - (d) Discrétisation par quantiles

Réponse : b

2. Le coefficient de Spearman mesure :
 - (a) La corrélation linéaire entre deux variables
 - (b) La corrélation de rang (monotone)
 - (c) La proportion de variance expliquée
 - (d) La distance entre deux distributions

Réponse : b

3. Dans la distance de Mahalanobis, la matrice utilisée est :
 - (a) La matrice des corrélations
 - (b) L'inverse de la matrice de variance-covariance
 - (c) La matrice des distances euclidiennes
 - (d) La matrice identité

Réponse : b

4. Un point atypique dans Isolation Forest a :
 - (a) Un chemin long dans l'arbre
 - (b) Un chemin court dans l'arbre
 - (c) Un score proche de 0
 - (d) Une forte contribution à l'inertie

Réponse : b

5. Le mécanisme MAR signifie que la probabilité de manquant :
 - (a) Est indépendante de toutes les données
 - (b) Dépend des données observées uniquement

- (c) Dépend des données manquantes uniquement
- (d) Dépend des données observées et manquantes

Réponse : b

6. Dans MICE, le nombre m de jeux de données imputés est typiquement :

- (a) $m = 1$
- (b) $m = 5$ à 20
- (c) $m = 100$ à 500
- (d) m est choisi par validation croisée

Réponse : b

7. Le Lasso effectue de la sélection de variables car :

- (a) Il utilise la norme ℓ_2
- (b) Il utilise la norme ℓ_1
- (c) Il estime les coefficients par MCO
- (d) Il orthogonalise les prédicteurs

Réponse : b

8. L'AFDM est adaptée aux données :

- (a) Uniquement qualitatives
- (b) Uniquement quantitatives
- (c) Mixtes (qualitatives et quantitatives)
- (d) Textuelles

Réponse : c

9. Le clustering de variables permet de :

- (a) Regrouper des individus similaires
- (b) Identifier des groupes de variables corrélées
- (c) Réduire le nombre d'individus
- (d) Détecter des points atypiques

Réponse : b

10. Pour des données volumineuses, une stratégie courante dans Isolation Forest est :

- (a) Utiliser tous les individus pour chaque arbre
- (b) Sous-échantillonner les individus pour chaque arbre
- (c) Augmenter le nombre de variables
- (d) Utiliser une ACP en amont

Réponse : b

Références

- [1] F.T. Liu, K.M. Ting, Z.-H. Zhou. Isolation Forest. *ICDM*, 2008.
- [2] V. Audigier, N. Niang. Exploitation des méthodes exploratoires pour le pré-traitement des données. Cours STA211, 2023.
- [3] S. van Buuren. *Flexible Imputation of Missing Data*. 2nd ed., CRC Press, 2018.
- [4] R. Tibshirani. Regression Shrinkage and Selection via the Lasso. *JRSS B*, 58(1):267–288, 1996.