

Fiche récapitulative – STA211

Classification de variables

Vincent Audigier, Ndèye Niang

12 juin 2026

Résumé

Cette fiche présente les méthodes de classification de variables. Lorsque les variables sont nombreuses, il est utile de les regrouper en classes homogènes pour analyser la multicolinéarité ou réduire la dimension. La fiche couvre les méthodes hiérarchiques (ascendante et descendante), les méthodes de partitionnement direct (CLV, ClustOfVar), les indices de similarité selon la nature des variables (quantitative, qualitative, binaire, mixte), et une application sur les données German Credit.

Table des matières

1	Objectifs et contexte	2
2	Méthodes hiérarchiques	2
2.1	Méthode ascendante (CAH)	2
2.1.1	Indices de similarité/dissimilarité	2
2.1.2	Critères d'agrégation	3
2.2	Méthode descendante	3
3	Partitionnement direct	3
3.1	Méthode CLV (Vigneau & Qannari, 2003)	3
3.2	ClustOfVar (Chavent et al., 2012)	4
4	Application aux données German Credit	4
4.1	Chargement et importation	4
4.2	CAH avec ClustOfVar	4
4.3	CAH avec CluMix	4
4.4	Partitionnement avec ClustOfVar	5
4.5	Partitionnement avec PAM	5
4.6	Comparaison des partitions	5
5	Conclusion	5
	Questions clés (QCM)	6

Objectifs et contexte

Quand les variables sont nombreuses, il est parfois très utile de les regrouper en groupes homogènes. Ceci peut servir à :

- Analyser la multicolinéarité entre les variables.
- Réduire le nombre de variables en leur substituant un petit nombre de variables latentes synthétiques représentatives de chaque classe.

On distingue trois stratégies de partitionnement :

1. Les méthodes hiérarchiques **ascendantes**.
2. Les méthodes hiérarchiques **descendantes**.
3. Les méthodes de **partitionnement direct**.

Méthodes hiérarchiques

Méthode ascendante (CAH)

Les groupements se font par agglomération progressive des variables deux à deux. On réunit les variables les plus proches au sens d'une dissimilarité, en utilisant un critère d'agrégation.

La complexité est en $O(p^3)$ où p est le nombre de variables.

Indices de similarité/dissimilarité

Le choix de l'indice dépend de la nature des variables.

Variables quantitatives : le coefficient de corrélation linéaire au carré $r_{jj'}^2$ est l'indice naturel de similarité. La dissimilarité associée $d = 1 - r^2$ est une distance euclidienne.

Variables qualitatives : les indices les plus classiques sont :

- χ^2 de contingence
- Tschuprow (T)
- Cramer (V)

Variables binaires : plusieurs indices définis à partir du tableau de contingence 2×2 ($N_{11}, N_{10}, N_{01}, N_{00}$) :

Indice	Formule
Sokal-Michener	$\frac{N_{11} + N_{00}}{N_{11} + N_{01} + N_{10} + N_{00}}$
Jaccard	$\frac{N_{11}}{N_{11} + N_{01} + N_{10}}$
Russel-Rao	$\frac{N_{11}}{N_{11} + N_{01} + N_{10} + N_{00}}$
Ochiai	$\frac{N_{11}}{\sqrt{(N_{11} + N_{01})(N_{11} + N_{10})}}$
Dice	$\frac{2N_{11} + N_{01} + N_{10}}{N_{11} + N_{00}}$
Rogers-Tanimoto	$\frac{N_{11} + 2(N_{01} + N_{10}) + N_{00}}{N_{11}}$
Kulzinsky	$\frac{N_{01} + N_{10}}{N_{11}}$

Remarque. Les mesures de dissimilarité associées sont toutes euclidiennes (Fichet & le Calve, 1984).

Variables mixtes : deux méthodes proposées par Hummel, Edelmann & Kopp-Schneider (2017) :

- **CluMix-ama** : similarité basée sur la valeur absolue du γ de Goodman-Kruskal pour les couples mixtes.
- **CluMix-dcor** : similarité basée sur une distance de Gower entre individus.

Ces méthodes sont implémentées dans le package R **CluMix** (archives CRAN).

Critères d'agrégation

Les critères sont les mêmes que pour la CAH d'individus :

- Saut minimum (*single linkage*)
- Saut maximum (*complete linkage*)
- Saut moyen (*average linkage*)
- Ward (si la dissimilarité est une distance euclidienne)

Méthode descendante

Procède par dichotomies successives pour construire un arbre hiérarchique. L'interprétation des classes est plus aisée car chaque classe est décrite par les règles de divisions successives.

Méthode VARCLUS (SAS) :

1. Réaliser une ACP des variables.
2. Si la seconde valeur propre > 1 , retenir les deux premières composantes.
3. Affecter chaque variable à la composante avec laquelle elle est le plus corrélée.
4. Répéter sur chaque groupe tant que la seconde valeur propre > 1 .

À retenir. La méthode VARCLUS est différente de ClustOfVar. Il existe une implémentation Python (**variable-clustering**) mais pas d'implémentation R standard.

Partitionnement direct

Méthode CLV (Vigneau & Qannari, 2003)

Destinée aux variables quantitatives. Approche similaire aux K -means, maximisant un critère de colinéarité intra-classe :

$$\sum_{k=1}^K \sum_{j=1}^p \delta_{k,j} \operatorname{cov}^2(x_j, u_k) \quad \text{sous contrainte} \quad \|u_k\| = 1 \quad (1)$$

où $\delta_{k,j} = 1$ si la variable j est dans la classe k , et u_k est la première composante principale de la classe k .

Algorithme :

1. Initialiser les classes.
2. Étape d'affectation : calculer $\delta_{k,j}$ (affecter chaque variable à la classe dont le centroïde est le plus proche).
3. Étape de mise à jour : recalculer u_k (1ère CP de chaque classe).
4. Répéter jusqu'à convergence.

ClustOfVar (Chavent et al., 2012)

Généralisation de CLV aux variables qualitatives ou mixtes :

- Utilise les composantes principales de l'ACM (qualitatives) ou de l'AFDM (mixtes) comme centroïde u_k .
- Similarité mesurée par le carré du rapport de corrélation (qualitative) ou le carré de la corrélation (quantitative).

À retenir. Les algorithmes de partitionnement direct de variables restent sensibles à leur initialisation. Il convient de tester plusieurs initialisations et de retenir celle optimisant le critère.

Application aux données German Credit

On utilise le jeu German Credit ($n = 1000$, $p = 21$, 7 quantitatives, 14 qualitatives) pour illustrer la classification de variables mixtes.

Chargement et importation

```
1 library(CluMix); library(ClustOfVar)
2 library(cluster); library(FactoMineR)
3 library(DescTools)
4
5 don <- read.table(
6   "https://archive.ics.uci.edu/ml/machine-learning-
7   databases/statlog/german/german.data",
8   sep = " ", stringsAsFactors = TRUE)
```

CAH avec ClustOfVar

```
1 var.factor <- which(sapply(don, class) == "factor")
2 var.numeric <- which(sapply(don, class) == "numeric" |
3   sapply(don, class) == "integer")
4 set.seed(1234)
5 res.cah.hclustvar <- hclustvar(X.quant = don[,var.numeric],
6   X.quali = don[,var.factor])
7 k_hclustvar <- 4
8 res.cutree <- cutreevar(res.cah.hclustvar, k = k_hclustvar)
```

CAH avec CluMix

```
1 # CluMix-ama
2 res.dendro_ama <- dendro.variables(don)
3 res.dendro_ama <- as.hclust(res.dendro_ama)
4 k_ama <- 3; part.cah.CluMix_ama <- cutree(res.dendro_ama, k = k_ama)
5
6 # CluMix-dcor
7 res.dendro_dcor <- dendro.variables(don, method = "distcor")
8 res.dendro_dcor <- as.hclust(res.dendro_dcor)
9 k_dcor <- 4; part.cah.CluMix_dcor <- cutree(res.dendro_dcor, k = k_dcor)
```

Partitionnement avec ClustOfVar

```

1 res.kmeansvar <- kmeansvar(X.quant = don[,var.numeric],
2                             X.quali = don[,var.factor],
3                             init = k_hclustvar, nstart = 100)
4
5 # Meilleure initialisation via CAH ou tirage aleatoire
6 myrandominit <- function(matdist, nb.centres){
7   random_centre <- sample(seq.int(ncol(don)), size = nb.centres)
8   random_part <- apply(matdist[,random_centre], 1, which.min)
9   return(random_part)
10 }
11 matsim <- PairApply(don, mixedVarSim, symmetric = TRUE)
12 matdist <- as.matrix(sqrt(round(1 - matsim, 5)))
13 random_init <- replicate(100, myrandominit(matdist, k_hclustvar),
14                           simplify = FALSE)
15
16 list.init <- list(cah.CluMix_dcor = part.cah.CluMix_dcor,
17                  cah.hclustvar = part.cah.hclustvar)
18 list.init <- c(list.init, random_init)
19
20 res.kmeansvar.new <- sapply(list.init, FUN = kmeansvar,
21   X.quant = don[,var.numeric], X.quali = don[,var.factor],
22   simplify = FALSE)
23 winner <- which.max(colSums(sapply(res.kmeansvar.new, "[", "wss")))
24 res.kmeansvar <- res.kmeansvar.new[[winner]]

```

Partitionnement avec PAM

```

1 diss.CluMix_ama <- dist.variables(don)
2 res.pam_ama <- pam(diss.CluMix_ama, diss = TRUE, k = k_ama)
3
4 diss.CluMix_dcor <- dist.variables(don, method = "distcor")
5 res.pam_dcor <- pam(diss.CluMix_dcor, diss = TRUE, k = k_dcor)

```

Comparaison des partitions

Une ACM sur le tableau des partitions met en évidence quatre groupes de variables :

1. **Profil personnel** : Length.of.current.employment, Sex.Marital.Status, Duration.in.Current.address, Age.years, Housing, No.of.dependents.
2. **Type de crédit et profil financier** : Duration, Purpose, Credit.Amount, Instalment.per.cent, Guarantors, Job, Telephone, Foreign.Worker.
3. **Actifs du demandeur** : Status, Savings account/bonds, Other.installment.plans, Creditability.
4. **Historique** : History, No.of.Credits.at.this.Bank.

Remarque. La variable Creditability (réponse) est liée au groupe des actifs, ce qui suggère une relation privilégiée avec ces variables.

Conclusion

La classification de variables vise à regrouper les variables en classes homogènes : les variables d'un même groupe sont fortement liées, celles de groupes différents sont faiblement liées.

Applications importantes :

- **Fuzzy forests** : variante des forêts aléatoires qui classifie d'abord les variables corrélées, puis effectue une sélection backward au sein de chaque groupe (package R **fuzzyforest**).

- **Biclustering** (co-clustering) : classification simultanée des individus et des variables pour identifier des groupes d'individus caractérisés par des sous-ensembles de variables.

Questions clés (QCM)

1. Quel est l'objectif principal de la classification de variables ?

- (a) Classifier les individus en groupes homogènes
- (b) Regrouper les variables en classes homogènes
- (c) Réduire le nombre d'individus
- (d) Augmenter la dimension des données

Réponse : b (regrouper les variables).

2. Quelle est la complexité de la CAH de variables ?

- (a) $O(n^2)$
- (b) $O(p^3)$
- (c) $O(n)$
- (d) $O(p)$

Réponse : b ($O(p^3)$ où p est le nombre de variables).

3. Quel indice de similarité est naturel pour des variables quantitatives ?

- (a) Le χ^2
- (b) Le V de Cramer
- (c) La corrélation au carré r^2
- (d) Le Jaccard

Réponse : c (coefficient de corrélation linéaire au carré).

4. Dans la méthode VARCLUS, quel critère déclenche une division ?

- (a) La première valeur propre > 1
- (b) La seconde valeur propre > 1
- (c) Le nombre de variables > 10
- (d) Le critère de Ward

Réponse : b (seconde valeur propre de l'ACP > 1).

5. Quel critère est maximisé par la méthode CLV ?

- (a) La variance inter-classe
- (b) La colinéarité intra-classe $\sum \text{cov}^2(x_j, u_k)$
- (c) Le χ^2 de contingence
- (d) La distance entre centroïdes

Réponse : b (somme des carrés des covariances entre les variables et le centroïde u_k).

6. Que représente u_k dans la méthode CLV ?

- (a) La moyenne des variables de la classe k
- (b) La première composante principale de la classe k
- (c) Le médoïde de la classe k
- (d) La variance de la classe k

Réponse : b (première composante principale).

7. Comment ClustOfVar étend CLV aux données mixtes ?

- (a) En utilisant la distance de Gower
- (b) En utilisant l'AFDM pour définir les centroïdes

- (c) En supprimant les variables qualitatives
- (d) En transformant les variables en binaires

Réponse : b (AFDM pour les centroïdes).

8. Quel package R implémente ClustOfVar ?

- (a) cluster
- (b) ClustOfVar
- (c) CluMix
- (d) FactoMineR

Réponse : b (ClustOfVar).

9. Que sont les fuzzy forests ?

- (a) Des forêts aléatoires avec classification préalable des variables
- (b) Des forêts aléatoires sans élagage
- (c) Des forêts aléatoires sur données floues
- (d) Une méthode de classification de variables

Réponse : a (random forest avec classification préalable des variables corrélées).

10. Qu'est-ce que le biclustering ?

- (a) Une classification d'individus seulement
- (b) Une classification de variables seulement
- (c) Une classification simultanée d'individus et de variables
- (d) Une méthode de régression

Réponse : c (classification simultanée individus $\times$ variables).

Références

- [1] V. Audigier, N. Niang. *STA211 : Classification de variables*. Cours CNAM, 23 février 2026.
- [2] M. Chavent, V. Kuentz-Simonet, B. Liquet, J. Saracco. *ClustOfVar: An R Package for the Clustering of Variables*. J. Stat. Soft., 50(13):1–16, 2012.
- [3] V. Vigneau, E. M. Qannari. *Clustering of variables around latent components*. Comm. Stat. Simul. Comput., 32(4):1131–1150, 2003.
- [4] M. Hummel, D. Edelmann, A. Kopp-Schneider. *Clustering of variables in the presence of mixed data*. Technical Report, 2017.
- [5] G. Saporta. *Probabilités, analyse des données et statistique*. Technip, 2006.
- [6] B. Fichet, G. le Calve. *Structure géométrique des principaux indices de dissimilarité sur signes de présence-absence*. Stat. Anal. Données, 9(3):11–44, 1984.