

Fiche récapitulative – STA211

Méthodes non-supervisées (introduction)

Vincent Audigier, Ndèye Niang

12 juin 2026

Résumé

Cette fiche présente une introduction aux méthodes non-supervisées en fouille de données. Elle couvre les méthodes de classification (partitionnement et hiérarchique), la classification de variables, les règles d'association, et les méthodes d'analyse factorielle (ACP, ACM, AFDM, méthodes multi-blocs). Les cartes de Kohonen font l'objet d'une fiche dédiée.

Table des matières

1	Contexte et panorama	2
2	Classification des individus	2
2.1	Méthodes de partitionnement	2
2.1.1	K-means	2
2.1.2	Partitionnement autour des médoïdes (PAM)	2
2.2	Méthodes hiérarchiques	2
2.2.1	CAH (Classification Ascendante Hiérarchique)	3
2.2.2	Méthode divisive	3
2.3	Choix du nombre de groupes	3
3	Classification de variables	3
3.1	Mesures de similarité entre variables	3
3.2	Application	4
4	Recherche de règles d'association	4
4.1	Définitions	4
4.2	Algorithme Apriori	4
4.3	Qualité des règles	4
5	Analyse factorielle	4
5.1	Méthodes classiques	5
5.2	Utilité en pré-traitement	5
5.3	Méthodes multi-blocs	5
6	Cartes de Kohonen (SOM)	5
6.1	Principe	5
6.2	Fonction de voisinage	6
7	Conclusion	6
	Questions clés (QCM)	6

Contexte et panorama

Les méthodes non-supervisées se distinguent des méthodes supervisées par l'absence de variable cible. L'objectif est de découvrir des structures, des groupes, ou des associations au sein des données, sans connaissance a priori.

On distingue trois grandes familles :

1. **Classification** (ou clustering) : identifier des groupes homogènes d'individus ou de variables.
2. **Recherche de règles d'association** : identifier des associations fréquentes entre items (ex. paniers d'achat).
3. **Analyse factorielle** : résumer les données par des graphiques de faible dimension (2D/3D) pour visualiser ressemblances entre individus et relations entre variables.

Les méthodes de classification peuvent être basées sur des distances (approches géométriques) ou sur des modèles. Les méthodes d'analyse factorielle sont complémentaires : elles peuvent servir de pré-traitement (transformation de variables qualitatives en quantitatives, réduction de dimension, amélioration de la partition via le *tandem clustering*).

Remarque. Les cartes de Kohonen (SOM), les méthodes de classification d'individus classiques (k-means, CAH) et les analyses factorielles de base (ACP, ACM, AFDM) sont supposées connues. Cette fiche présente une synthèse et les prolongements (classification de variables, méthodes multi-blocs).

Classification des individus

Méthodes de partitionnement

Les méthodes de partitionnement consistent à définir une partition de l'ensemble des individus en K groupes (défini à l'avance) telle que la dispersion intra-groupe soit minimale et la dispersion inter-groupe maximale.

K-means

L'algorithme des K -means (MacQueen, 1967; Forgy, 1965) minimise l'inertie intra-classe :

$$W(C) = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2 \quad (1)$$

où μ_k est le centroïde du groupe C_k .

Algorithme :

1. Choisir K centres initiaux (aléatoirement ou via K -means++).
2. Affecter chaque individu au centre le plus proche (distance euclidienne).
3. Recalculer les centres comme moyenne des individus du groupe.
4. Répéter 2–3 jusqu'à convergence (stabilité des affectations).

À retenir. K -means est sensible aux centres initiaux et aux valeurs atypiques. On utilise K -means++ pour une initialisation robuste.

Partitionnement autour des médoïdes (PAM)

Alternative robuste à K -means utilisant des médoïdes (individus réels plutôt que des moyennes) comme centres. Accepte toute matrice de dissimilarité.

Méthodes hiérarchiques

Les méthodes hiérarchiques construisent une hiérarchie de partitions, représentée par un dendrogramme. L'utilisateur choisit la partition finale en coupant l'arbre à un niveau donné.

CAH (*Classification Ascendante Hiérarchique*)

Algorithme agglomératif :

1. Initialiser chaque individu comme un groupe.
2. Fusionner les deux groupes les plus proches (selon un critère de saut minimal).
3. Répéter jusqu'à obtenir un seul groupe.

Principaux critères de saut (liens) :

Critère	Distance entre groupes A et B
Saut minimum	$\min_{i \in A, j \in B} d(i, j)$
Saut maximum	$\max_{i \in A, j \in B} d(i, j)$
Lien moyen	$\frac{1}{ A B } \sum_{i \in A} \sum_{j \in B} d(i, j)$
Ward	$\frac{ A B }{ A + B } \ \mu_A - \mu_B\ ^2$

Remarque. Le critère de Ward est le plus utilisé : il minimise la perte d'inertie intra-classe à chaque fusion.

Méthode divisive

Approche inverse de la CAH : on part d'un seul groupe que l'on divise récursivement. Moins utilisée car plus coûteuse ($O(2^n)$ sans heuristiques).

Choix du nombre de groupes

Plusieurs critères pour déterminer K :

- **Méthode du coude** (elbow) : inertie intra-classe en fonction de K ; on cherche le point d'inflexion.
- **Indice de silhouette** : mesure la cohésion interne et la séparation des groupes $\in [-1, 1]$.
- **Indice de Davies–Bouldin** : rapport de la dispersion intra-groupe à la distance inter-groupes (minimiser).
- **Saut de variance** (*gap statistic*) : compare l'inertie observée à celle attendue sous une distribution de référence.

Classification de variables

La classification de variables est similaire dans son principe à celle des individus, mais présente des particularités liées à la nature des variables (quantitatives, qualitatives, mixtes).

Mesures de similarité entre variables

- **Variables quantitatives** : corrélation de Pearson, corrélation de Spearman, information mutuelle.
- **Variables qualitatives** : V de Cramer, ϕ de contingence, information mutuelle normalisée.
- **Variables mixtes** : coefficient de corrélation de Pearson entre les rapports de corrélation (via l'AFDM).

Application

On peut appliquer une CAH ou K -means sur la matrice de similarité entre variables après transformation en dissimilarité ($d = 1 - s$). L'objectif est de former des groupes de variables redondantes pour les résumer.

À retenir. La classification de variables est utile pour la sélection de variables (garder une variable représentative par groupe) et pour l'interprétation des résultats d'analyses factorielles.

Recherche de règles d'association

Les règles d'association sont très utilisées en marketing (analyse de paniers d'achat). Elles consistent à identifier des associations fréquentes entre items.

Définitions

Soit un ensemble d'items $\mathcal{I} = \{i_1, \dots, i_m\}$ et un ensemble de transactions $\mathcal{T} = \{t_1, \dots, t_n\}$ où chaque transaction $t \subseteq \mathcal{I}$.

Une règle d'association est une implication $X \Rightarrow Y$ où $X, Y \subseteq \mathcal{I}$ et $X \cap Y = \emptyset$.

- **Support** : fréquence de l'itemset X : $\text{supp}(X) = \frac{|\{t \in \mathcal{T} : X \subseteq t\}|}{n}$
- **Confiance** : probabilité conditionnelle de Y sachant X : $\text{conf}(X \Rightarrow Y) = \frac{\text{supp}(X \cup Y)}{\text{supp}(X)}$
- **Lift** : rapport entre la confiance et le support de Y : $\text{lift}(X \Rightarrow Y) = \frac{\text{supp}(X \cup Y)}{\text{supp}(X) \text{supp}(Y)}$

Remarque. Un lift > 1 indique une association positive (les items apparaissent plus souvent ensemble que sous l'indépendance). Un lift < 1 indique une association négative.

Algorithme Apriori

L'algorithme Apriori (Agrawal & Srikant, 1994) procède en deux étapes :

1. **Génération des itemsets fréquents** : on parcourt les itemsets par taille croissante en élaguant ceux dont le support est inférieur à un seuil $\text{supp}_{\min}$ (propriété d'anti-monotonie : tout sur-ensemble d'un itemset non fréquent est non fréquent).
2. **Génération des règles** : à partir des itemsets fréquents, on génère les règles $X \Rightarrow Y$ vérifiant $\text{conf} \geq \text{conf}_{\min}$.

Qualité des règles

Plusieurs mesures pour évaluer une règle :

- Confiance (défaut)
- Lift
- Conviction : $\frac{1 - \text{supp}(Y)}{1 - \text{conf}(X \Rightarrow Y)}$
- Levier : $\text{supp}(X \cup Y) - \text{supp}(X) \text{supp}(Y)$

Analyse factorielle

Les méthodes d'analyse factorielle sont des approches géométriques qui résument les données sous forme de graphiques de dimension réduite (généralement 2 ou 3).

Méthodes classiques

- **ACP (Analyse en Composantes Principales)** : pour des variables quantitatives. Réduit la dimension en projetant les données sur des axes maximisant la variance (inertie).
- **ACM (Analyse des Correspondances Multiples)** : pour des variables qualitatives. Étend l'analyse des correspondances à plus de deux variables.
- **AFDM (Analyse Factorielle de Données Mixtes)** : pour des données mixtes (quantitatives + qualitatives). Combine ACP et ACM en une analyse unique.

Utilité en pré-traitement

L'analyse factorielle est complémentaire aux méthodes de classification :

- **Transformation de variables** : remplacer des variables qualitatives par les coordonnées factorielles pour appliquer des méthodes qui nécessitent des variables quantitatives (K -means, régression).
- **Réduction de dimension** : travailler dans un espace de dimension réduite pour atténuer le fléau de la dimension (*curse of dimensionality*).
- **Tandem clustering** : appliquer une classification (K -means, CAH) sur les coordonnées factorielles plutôt que sur les variables originales, ce qui améliore généralement la qualité de la partition.
- **Visualisation** : les plans factoriels permettent de visualiser la partition obtenue et d'interpréter les groupes.

Méthodes multi-blocs

Les méthodes multi-blocs constituent un prolongement des analyses factorielles classiques. Elles permettent d'analyser simultanément plusieurs tableaux de données (blocs) mesurés sur les mêmes individus.

Les principales méthodes sont :

- **DACP (Diagonalisation d'un Tableau de Covariance Par blocs)** : généralisation de l'ACP à plusieurs blocs.
- **STATIS (Structuration des Tableaux à Trois Indices de la Statistique)** : méthode en quatre phases (interstructure, compromis, intrastructure, analyse du compromis).
- **AFM (Analyse Factorielle Multiple)** : équivalent de l'AFDM pour les blocs de variables, avec une pondération équilibrante des blocs.

À retenir. Les méthodes multi-blocs sont traitées en détail dans une fiche dédiée.

Cartes de Kohonen (SOM)

Les cartes autoorganisatrices de Kohonen (Self-Organizing Maps, SOM) sont des réseaux de neurones non supervisés qui réalisent simultanément une réduction de dimension et une classification.

Principe

Une carte de Kohonen projette les données de haute dimension sur une grille (généralement 2D) tout en préservant la topologie des données : deux individus proches dans l'espace original restent proches sur la grille.

- **Grille** : ensemble de neurones organisés selon une topologie (rectangulaire, hexagonale).
- **Vecteurs de référence** : chaque neurone i possède un vecteur w_i de même dimension que les données.

- **Apprentissage** : on présente chaque observation x et on détermine le neurone vainqueur (celui dont le vecteur w_i est le plus proche de x au sens de la distance euclidienne). On met à jour w_i et les neurones voisins dans la grille.

Fonction de voisinage

La mise à jour du vecteur du neurone vainqueur c et de ses voisins suit :

$$w_i(t+1) = w_i(t) + \alpha(t) h_{ci}(t) (x(t) - w_i(t)) \quad (2)$$

où :

- $\alpha(t)$ est le taux d'apprentissage (décroissant).
- $h_{ci}(t)$ est la fonction de voisinage (gaussienne ou “chapeau mexicain”), qui décroît avec la distance entre les neurones c et i sur la grille.

Remarque. Les cartes de Kohonen sont traitées en détail dans une fiche dédiée.

Conclusion

Les méthodes non-supervisées forment un pilier essentiel de la fouille de données :

- La **classification** (partitionnement, hiérarchique, cartes de Kohonen) permet de découvrir des groupes homogènes.
- Les **règles d'association** identifient des liens fréquents entre items dans de grands volumes de données.
- L'**analyse factorielle** (ACP, ACM, AFDM, multi-blocs) offre des visualisations synthétiques et sert de pré-traitement pour la classification.
- La **classification de variables** complète la boîte à outils en permettant de regrouper des variables redondantes.

Ces méthodes sont complémentaires et peuvent être combinées (séquence analyse factorielle → classification, *tandem clustering*) pour une exploration efficace des données.

Questions clés (QCM)

1. Quelle est la principale différence entre méthodes supervisées et non supervisées ?
 - (a) Les méthodes non supervisées nécessitent une variable cible
 - (b) Les méthodes supervisées nécessitent une variable cible
 - (c) Il n'y a pas de différence
 - (d) Les méthodes non supervisées sont plus rapides

Réponse : b (les méthodes supervisées nécessitent une variable cible).

2. Dans K -means, que minimise-t-on ?
 - (a) L'inertie inter-classe
 - (b) L'inertie intra-classe
 - (c) La variance totale
 - (d) Le nombre de groupes

Réponse : b (l'inertie intra-classe).

3. Quel critère de saut est le plus utilisé en CAH ?
 - (a) Saut minimum
 - (b) Saut maximum
 - (c) Lien moyen

(d) Ward

Réponse : d (Ward, qui minimise la perte d'inertie intra-classe).

4. Que mesure le support d'un itemset X ?

- (a) La probabilité de X sachant Y
- (b) La fréquence de X dans les transactions
- (c) La force de l'association $X \Rightarrow Y$
- (d) Le nombre d'items dans X

Réponse : b (fréquence de X dans les transactions).

5. Un lift > 1 indique :

- (a) Une association négative
- (b) Une association positive
- (c) Aucune association
- (d) Une erreur de calcul

Réponse : b (association positive : les items apparaissent plus souvent ensemble que sous l'indépendance).

6. Quelle analyse factorielle est adaptée aux données quantitatives ?

- (a) ACM
- (b) ACP
- (c) AFDM
- (d) AFC

Réponse : b (ACP – Analyse en Composantes Principales).

7. Quelle analyse factorielle est adaptée aux données qualitatives ?

- (a) ACP
- (b) ACM
- (c) AFDM
- (d) Toutes les réponses

Réponse : b (ACM – Analyse des Correspondances Multiples).

8. Qu'est-ce que le *tandem clustering* ?

- (a) Appliquer deux classifications successives
- (b) Appliquer une analyse factorielle puis une classification
- (c) Appliquer une classification puis une analyse factorielle
- (d) Mélanger deux algorithmes de classification

Réponse : b (analyse factorielle puis classification).

9. Quelle propriété permet l'élagage dans l'algorithme Apriori ?

- (a) La monotonie du support
- (b) L'anti-monotonie du support
- (c) La symétrie de la confiance
- (d) La transitivité du lift

Réponse : b (anti-monotonie : tout sur-ensemble d'un itemset non fréquent est non fréquent).

10. Dans les cartes de Kohonen, que préserve la projection ?

- (a) Les distances exactes entre individus
- (b) La topologie des données
- (c) La variance des variables
- (d) L'ordre des individus

Réponse : b (la topologie : deux individus proches dans l'espace original restent proches sur la grille).

Références

- [1] V. Audigier, N. Niang. *STA211 : Méthodes non-supervisées (introduction)*. Cours CNAM, 20 février 2026.
- [2] J. MacQueen. *Some methods for classification and analysis of multivariate observations*. Proc. 5th Berkeley Symp. Math. Statist. Probab., 1967.
- [3] R. Agrawal, R. Srikant. *Fast algorithms for mining association rules*. VLDB, 1994.
- [4] T. Kohonen. *Self-organized formation of topologically correct feature maps*. Biological Cybernetics, 43(1):59–69, 1982.
- [5] R. Rakotomalala. *Classification ascendante hiérarchique*. <https://eric.univ-lyon2.fr/ricco/cours/cours/CAH.pdf>