

Fiche récapitulative – STA211

Recherche de règles d'association

Vincent Audigier, Ndèye Niang

12 juin 2026

Résumé

Cette fiche présente les méthodes de recherche de règles d'association, initialement développées pour l'analyse des paniers d'achat (Agrawal et al., 1993). Elle couvre les concepts fondamentaux (items, transactions, itemsets, support, confiance), l'algorithme Apriori et sa propriété d'anti-monotonie, les algorithmes alternatifs (représentation horizontale et verticale), les indices de pertinence (lift, conviction, leverage) ainsi que des exemples d'application sur données supermarché et German Credit.

Table des matières

1	Introduction	2
2	Définitions et concepts de base	2
2.1	Items, transactions et règles	2
2.2	Support et confiance	2
3	L'algorithme Apriori	2
3.1	Recherche des itemsets fréquents	2
3.2	Extraction des règles	2
4	Algorithmes alternatifs	3
4.1	Représentation horizontale	3
4.2	Représentation verticale	3
5	Indices de pertinence des règles	3
5.1	Faiblesse de l'approche support-confiance	3
5.2	Indices complémentaires	3
6	Exemples	3
6.1	Supermarché	3
6.2	German Credit	4
7	Conclusion	4
	Questions clés (QCM)	4

Introduction

Les méthodes de recherche de règles d'association ont été proposées par [1] pour découvrir quels produits étaient achetés conjointement dans les bases de données des ventes de supermarché. Elles permettent d'extraire des règles du type :

“Lorsqu’un client achète du pain et du beurre, alors neuf fois sur dix il achète en même temps du lait.”

Bien que développées initialement pour le marketing, ces méthodes s'appliquent également au webmining (analyse de consultation de pages web), au text mining (cooccurrences de termes), etc.

Définitions et concepts de base

Items, transactions et règles

On définit $I = \{it_1, it_2, \dots, it_p\}$ l'ensemble des **items** (produits d'un supermarché par exemple). Une **transaction** tr_j est un sous-ensemble non vide de I ; on note $T = \{tr_1, tr_2, \dots, tr_n\}$ l'ensemble des n transactions (contenus de caddies).

Une **règle d'association** est une implication $A \rightarrow B$ où $A \subset I$, $B \subset I$ et $A \cap B = \emptyset$. A est la prémisse (antécédent), B la conclusion (conséquent). Les ensembles A et B sont appelés **itemsets**.

Support et confiance

Définition (Support). Le support d'un itemset X est la proportion de transactions contenant X :

$$\text{supp}(X) = \frac{|\{t \in T : X \subseteq t\}|}{|T|} \quad (1)$$

Définition (Confiance). La confiance d'une règle $A \rightarrow B$ est la proportion de transactions contenant B parmi celles contenant A :

$$\text{conf}(A \rightarrow B) = \frac{\text{supp}(A \cup B)}{\text{supp}(A)} \quad (2)$$

À retenir. Le support mesure la **généralité** d'une règle ; la confiance mesure sa **fiabilité**. On impose généralement des seuils minimaux $\text{supp}_{\min}$ et $\text{conf}_{\min}$.

L'algorithme Apriori

L'algorithme Apriori ([2]) procède en deux étapes : génération des itemsets fréquents puis extraction des règles.

Recherche des itemsets fréquents

On explore le treillis des itemsets par parcours en largeur (de taille 1 jusqu'à p). À chaque niveau k , on génère les candidats de taille k à partir des itemsets fréquents de taille $k - 1$, puis on élague ceux dont le support est inférieur à $\text{supp}_{\min}$.

La propriété d'**anti-monotonie** garantit l'élagage :

À retenir. Tout sur-ensemble d'un itemset non fréquent est nécessairement non fréquent.

Si un itemset de taille $k - 1$ a un support $< \text{supp}_{\min}$, tous ses sur-ensembles de taille k peuvent être éliminés sans calcul supplémentaire.

Extraction des règles

À partir des itemsets fréquents, on génère toutes les règles $A \rightarrow B$ telles que $\text{conf}(A \rightarrow B) \geq \text{conf}_{\min}$.

Algorithmes alternatifs

Représentation horizontale

Les données sont stockées sous forme d'une liste de transactions (une ligne par transaction, chaque ligne contient la liste des items achetés). Apriori utilise cette représentation.

Représentation verticale

Les données sont stockées sous forme d'une liste d'items : pour chaque item, on stocke la liste des identifiants de transactions qui le contiennent (format *tid-list*). Avantage : le support d'un itemset s'obtient par intersection des *tid-lists*.

Indices de pertinence des règles

Faiblesse de l'approche support-confiance

Une règle peut avoir une confiance élevée mais être trompeuse si le conséquent est fréquent dans la population. Par exemple, si 90 % des clients achètent du lait, une règle $X \rightarrow \text{lait}$ aura une confiance d'au moins 90 % quel que soit X .

Indices complémentaires

Définition (Lift). Le lift mesure l'écart à l'indépendance :

$$\text{lift}(A \rightarrow B) = \frac{\text{supp}(A \cup B)}{\text{supp}(A) \text{supp}(B)} \quad (3)$$

Interprétation :

- $\text{lift} > 1$: association positive (items achetés plus souvent ensemble que sous l'indépendance).
- $\text{lift} = 1$: indépendance.
- $\text{lift} < 1$: association négative.

Définition (Conviction).

$$\text{conviction}(A \rightarrow B) = \frac{1 - \text{supp}(B)}{1 - \text{conf}(A \rightarrow B)} \quad (4)$$

Mesure la dépendance directionnelle : plus la conviction est grande, plus la règle est robuste.

Définition (Leverage).

$$\text{leverage}(A \rightarrow B) = \text{supp}(A \cup B) - \text{supp}(A) \text{supp}(B) \quad (5)$$

Exemples

Supermarché

Soit 5 transactions :

Transaction	Items
tr_1	{pain, lait, beurre, bière}
tr_2	{pain, beurre}
tr_3	{bière, cacahuètes}
tr_4	{pain, lait, beurre}
tr_5	{pain, lait}

Avec $\text{supp}_{\min} = 0,4$:

- $\text{supp}(\{\text{pain}\}) = 4/5 = 0,8$: fréquent.
- $\text{supp}(\{\text{pain}, \text{beurre}\}) = 3/5 = 0,6$: fréquent.
- $\text{supp}(\{\text{cacahuètes}\}) = 1/5 = 0,2$: non fréquent.
- Règle $\{\text{pain}\} \rightarrow \{\text{beurre}\}$:
 - $\text{supp} = 3/5 = 0,6$
 - $\text{conf} = 3/4 = 0,75$
 - $\text{lift} = 0,6/(0,8 \times 0,6) = 1,25 > 1$

German Credit

Les règles d'association peuvent être extraites après discrétisation des variables quantitatives avec l'algorithme Apriori via le package R `arules`.

```
1 library(arules)
2
3 # Discrétisation des variables quantitatives
4 don_disc <- discretizeDF(don, default = list(method = "interval",
5                                           breaks = 3))
6
7 # Extraction des règles
8 regles <- apriori(don_disc,
9                  parameter = list(supp = 0.05, conf = 0.3,
10                                target = "rules"))
11 inspect(head(regles, 5))
```

Conclusion

Les méthodes de recherche de règles d'association permettent d'extraire des connaissances sous forme de règles interprétables à partir de grandes bases de données. L'algorithme Apriori reste la méthode de référence grâce à son élagage par anti-monotonie. Les indices de pertinence (lift, conviction, leverage) complètent l'approche support-confiance pour éviter les règles trompeuses.

Applications principales :

- Analyse de paniers d'achat (marketing).
- Webmining (analyse de navigation).
- Text mining (cooccurrences de termes).
- Analyse de données médicales (associations de symptômes).

Questions clés (QCM)

1. Que représente le support d'un itemset X ?
 - (a) La probabilité de X sachant Y
 - (b) La proportion de transactions contenant X
 - (c) La force de l'association $X \Rightarrow Y$
 - (d) Le nombre d'items dans X

Réponse : b (proportion de transactions contenant X).

2. Que mesure la confiance d'une règle $A \rightarrow B$?
 - (a) $\frac{\text{supp}(A \cup B)}{\text{supp}(A)}$

- (b) $\frac{\text{supp}(A)}{\text{supp}(B)}$
- (c) $\frac{\text{supp}(A \cup B)}{\text{supp}(B)}$
- (d) $\frac{\text{supp}(A)}{\text{supp}(A \cup B)}$

Réponse : a ($\text{supp}(A \cup B)/\text{supp}(A)$).

3. Quelle propriété permet l'élagage dans Apriori ?

- (a) La monotonie du support
- (b) L'anti-monotonie du support
- (c) La symétrie de la confiance
- (d) La transitivité du lift

Réponse : b (anti-monotonie : tout sur-ensemble d'un itemset non fréquent est non fréquent).

4. Un lift > 1 indique :

- (a) Une association négative
- (b) Une association positive
- (c) Aucune association
- (d) Une erreur de calcul

Réponse : b (association positive).

5. Quelle est la particularité de la représentation verticale des données ?

- (a) Chaque ligne est une transaction
- (b) Pour chaque item, on stocke la liste des transactions (tid-list)
- (c) Les données sont stockées sous forme matricielle
- (d) Elle nécessite moins de mémoire qu'Apriori

Réponse : b (format tid-list).

6. Quel package R implémente l'algorithme Apriori ?

- (a) `arules`
- (b) `cluster`
- (c) `FactoMineR`
- (d) `MASS`

Réponse : a (arules).

7. Que mesure la conviction d'une règle ?

- (a) Le support conditionnel
- (b) La dépendance directionnelle entre prémisse et conclusion
- (c) La fréquence de l'itemset
- (d) La dissimilarité entre items

Réponse : b (dépendance directionnelle).

8. Dans l'exemple du supermarché avec 5 transactions, quel est le support de {pain, beurre} ?

- (a) $3/5 = 0,6$
- (b) $4/5 = 0,8$
- (c) $2/5 = 0,4$
- (d) $1/5 = 0,2$

Réponse : a ($3/5$).

9. Quel est l'inconvénient de l'approche support-confiance ?

- (a) Elle est trop complexe

- (b) Une règle peut avoir une confiance élevée mais être trompeuse si le conséquent est fréquent
- (c) Elle ne fonctionne que pour les données binaires
- (d) Elle nécessite trop de mémoire

Réponse : b (confiance élevée mais règle trompeuse).

10. Qui a proposé l'algorithme Apriori ?

- (a) Vigneau et Qannari
- (b) Agrawal, Imieliński et Swami
- (c) Chavent et al.
- (d) Breiman

Réponse : b (Agrawal, Imieliński et Swami, 1993).

Références

- [1] R. Agrawal, T. Imieliński, A. Swami. *Mining association rules between sets of items in large databases*. Proc. ACM SIGMOD, 22(2):207–216, 1993.
- [2] R. Agrawal, R. Srikant. *Fast algorithms for mining association rules in large databases*. Proc. VLDB, 487–499, 1994.
- [3] M. Plasse. *Regroupement d'items dans les problèmes de recherche de règles d'association*. Thèse de doctorat, CNAM, 2006.